삼성전기 AI전문가 양성과정 - 프로젝트 실습 (비영상)

# 자연어처리를 위한 RNN (Recurrent Neural Network)

현청천

2022.02.28

## What is RNN

- 시계열(Sequential Data) 데이터를 처리하기 위한 Neural Network
  - 음성, 언어, 주가, 센서 데이터 등







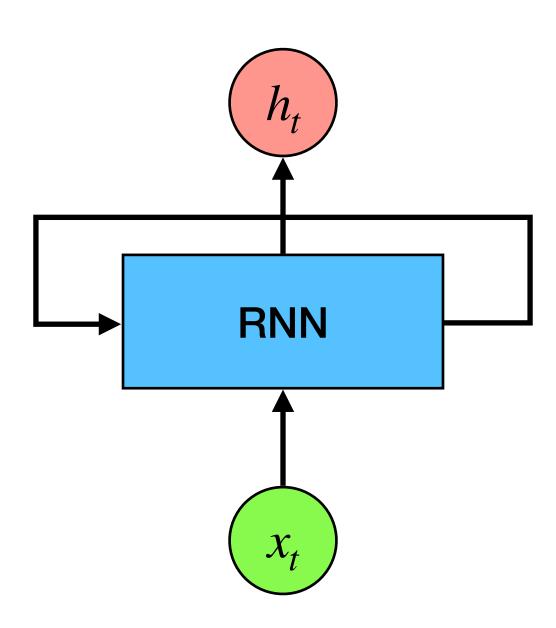
### What is RNN

- 시계열(Sequential Data) 데이터를 처리하기 위한 Neural Network
  - 음성, 언어, 주가, 센서 데이터 등
- 문장에서 이전에 나온 단어를 보가 다음단어를 예측

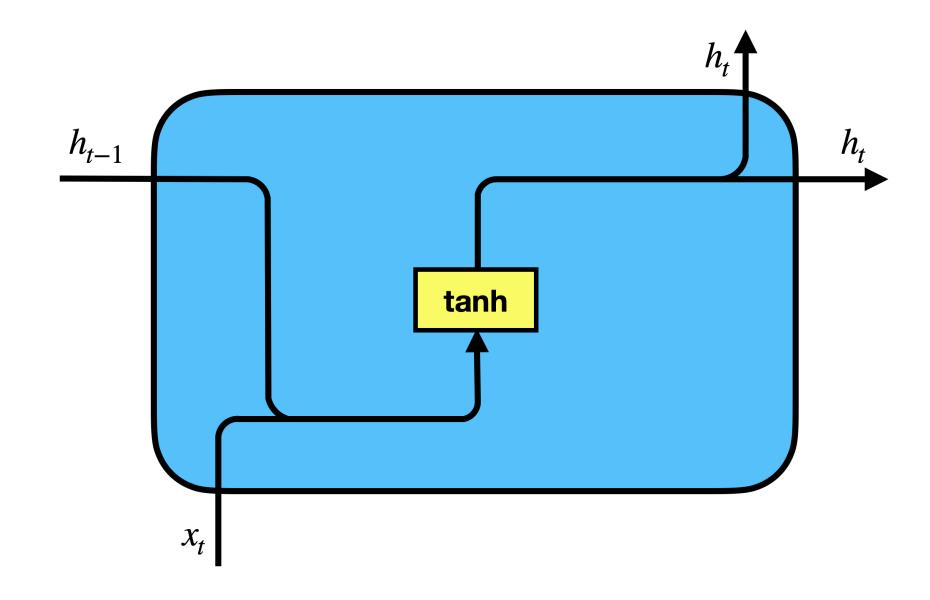


### What is RNN

- 시계열(Sequential Data) 데이터를 처리하기 위한 모델
  - 음성, 언어, 주가, 센서 데이터 등
- 문장에서 이전에 나온 단어를 보가 다음단어를 예측
- 동일한 Weight와 Bias가 모든 입력 값에 대해서 동일하게 사용 됨



$$h_t = tanh(W_h h_{t-1} + W_x x_t + b)$$



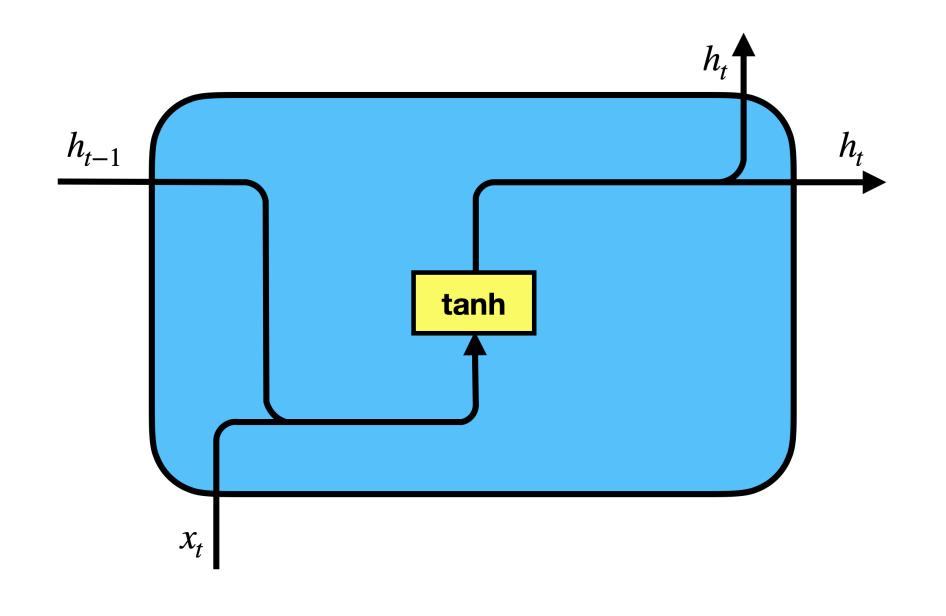
Sequencial Data

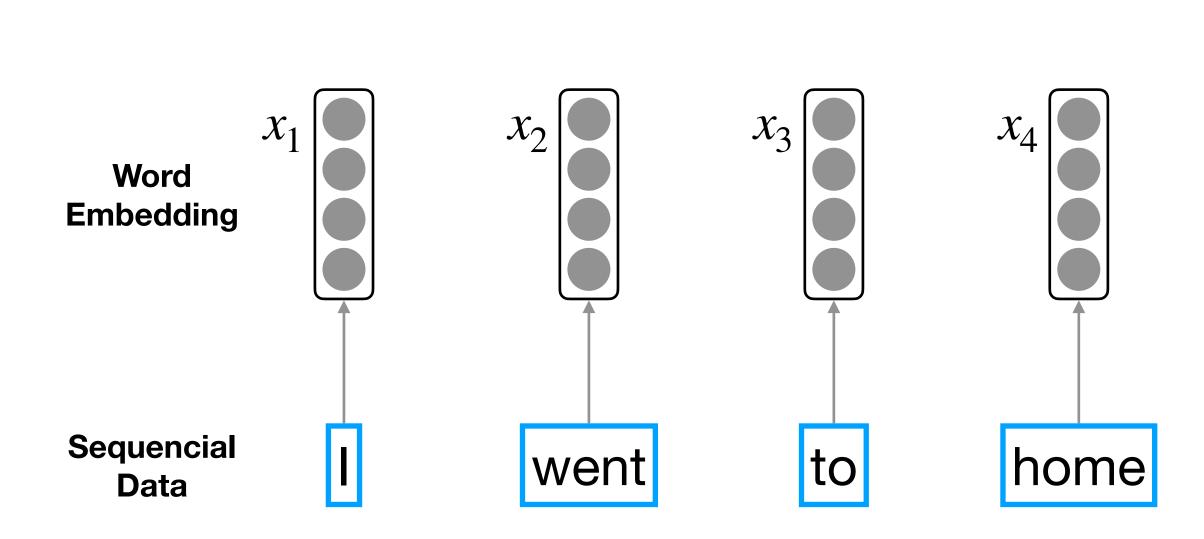
went

to

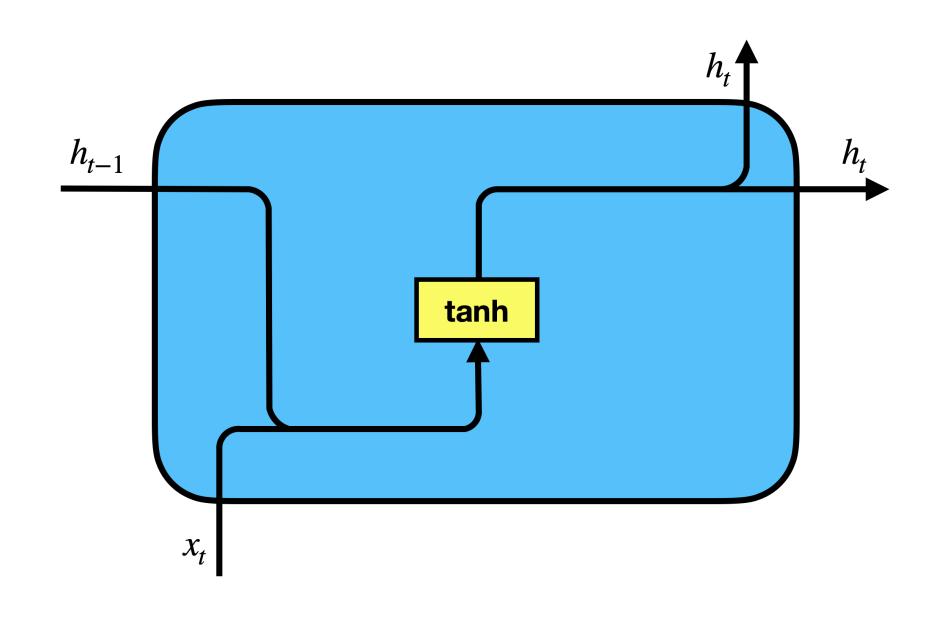
home

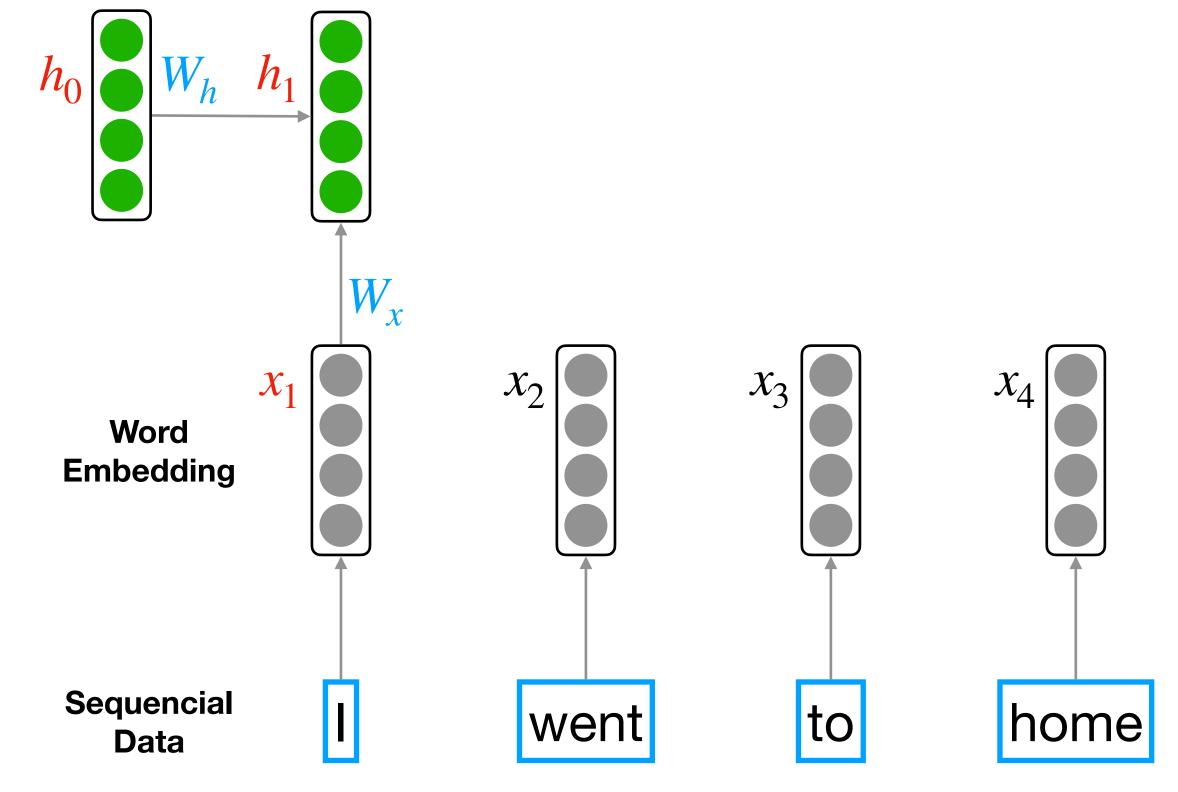
$$h_t = tanh(W_h h_{t-1} + W_x x_t + b)$$



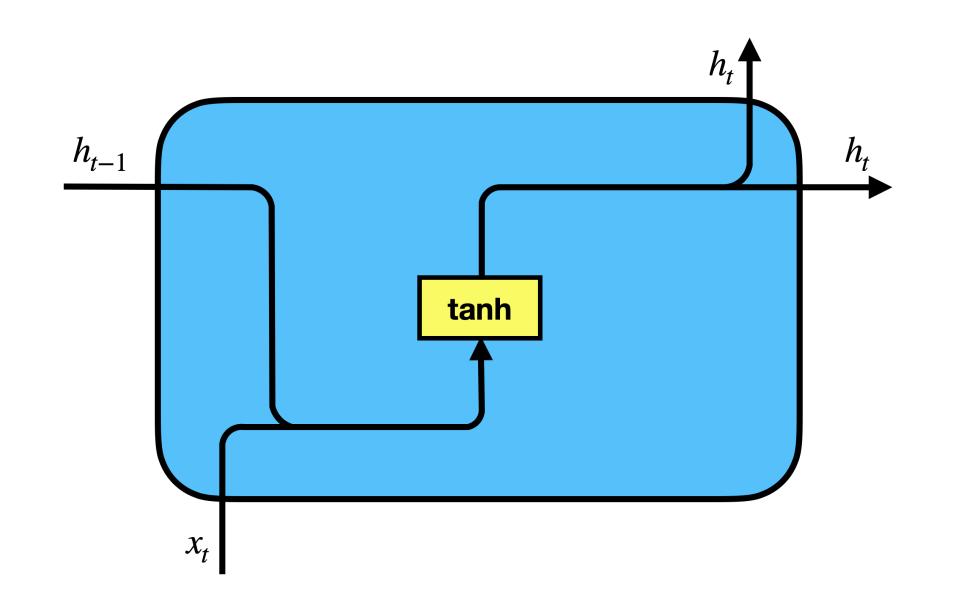


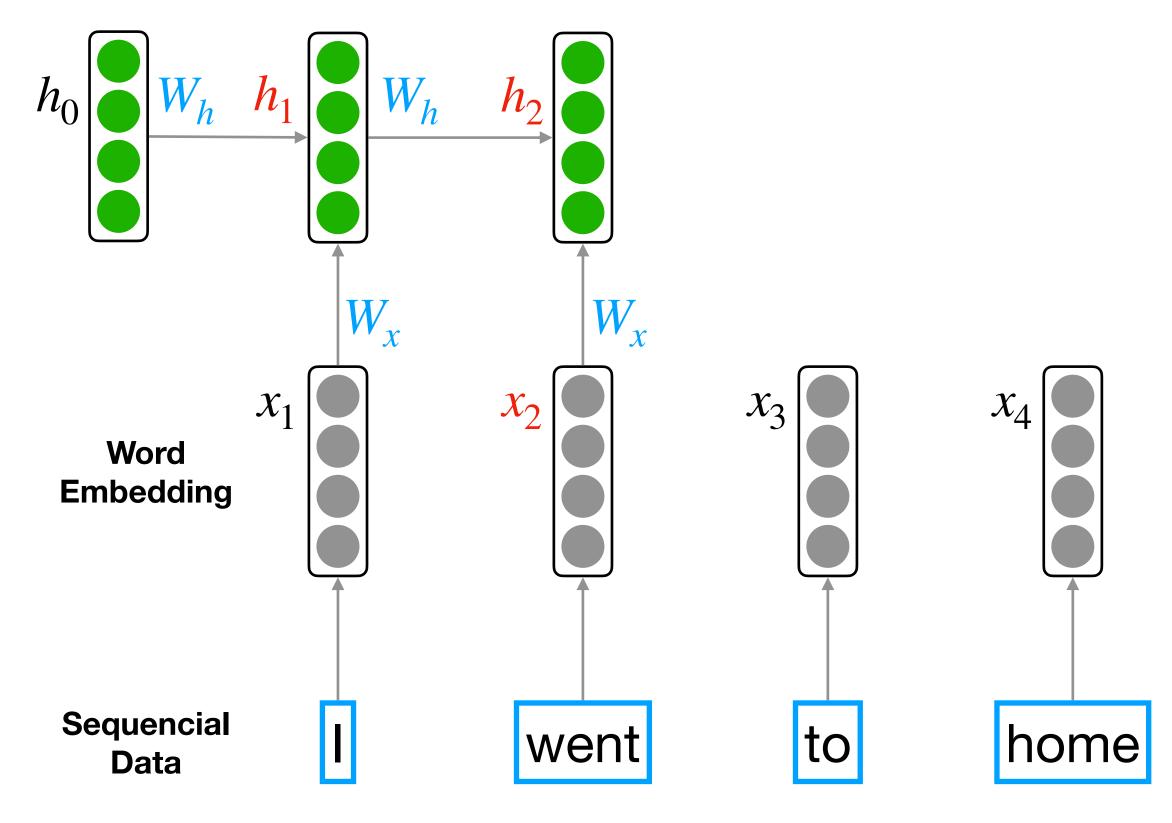
$$h_t = tanh(W_h h_{t-1} + W_x x_t + b)$$



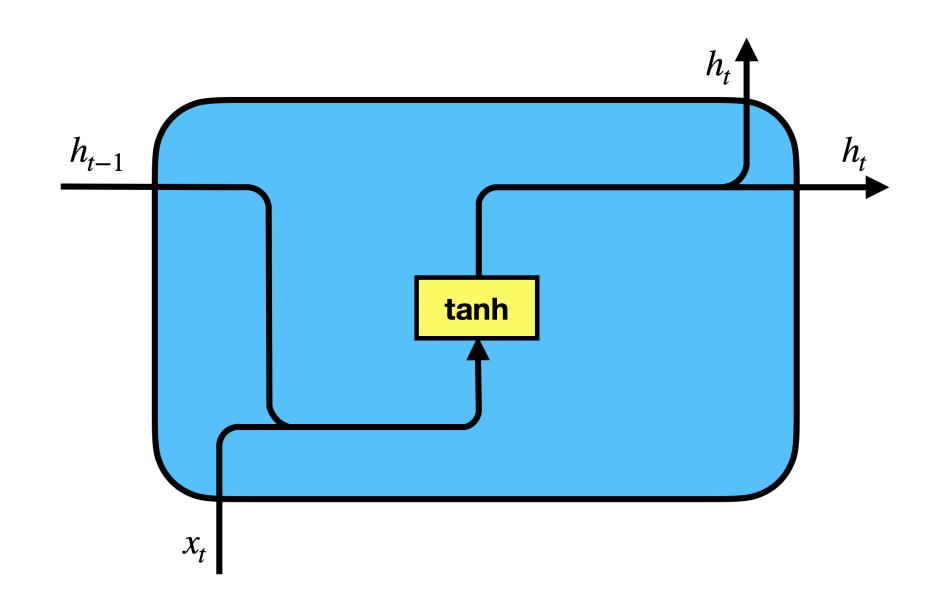


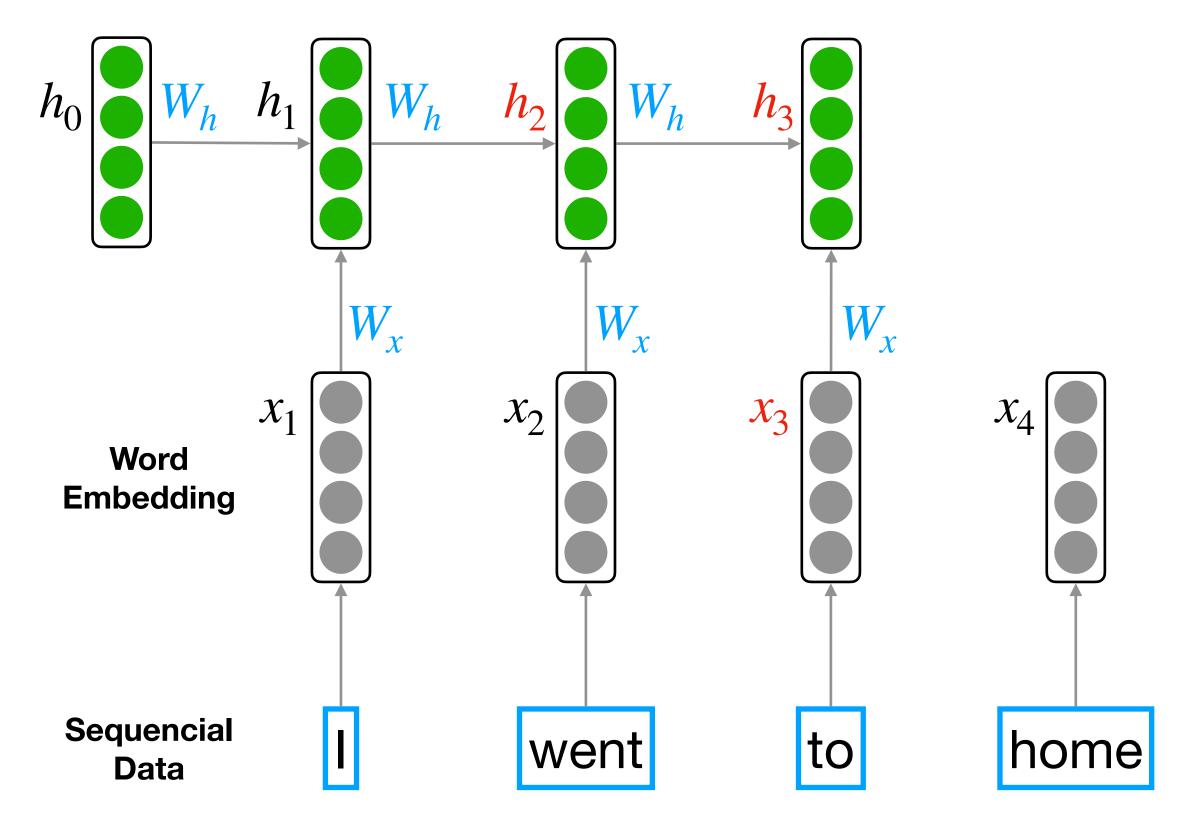
$$h_t = tanh(W_h h_{t-1} + W_x x_t + b)$$



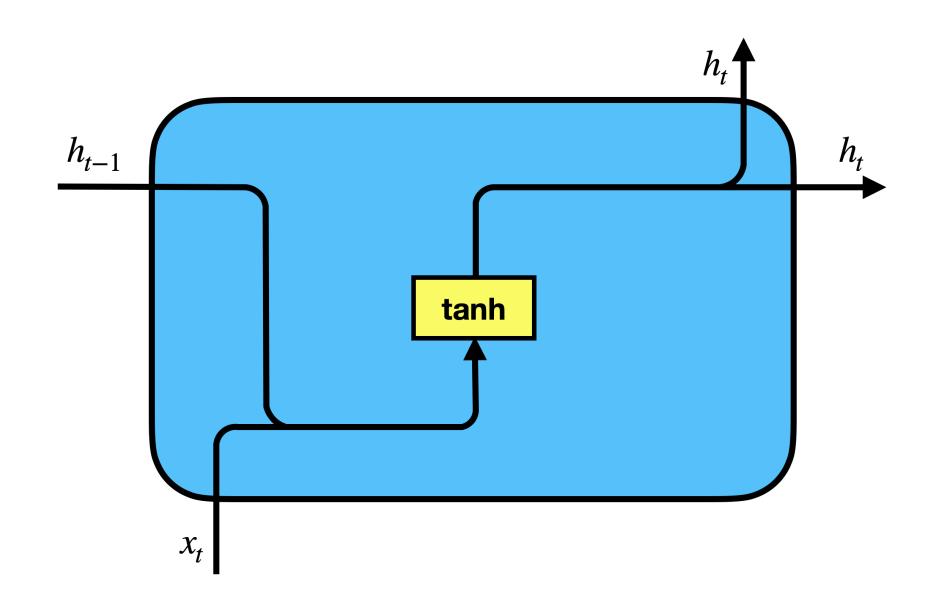


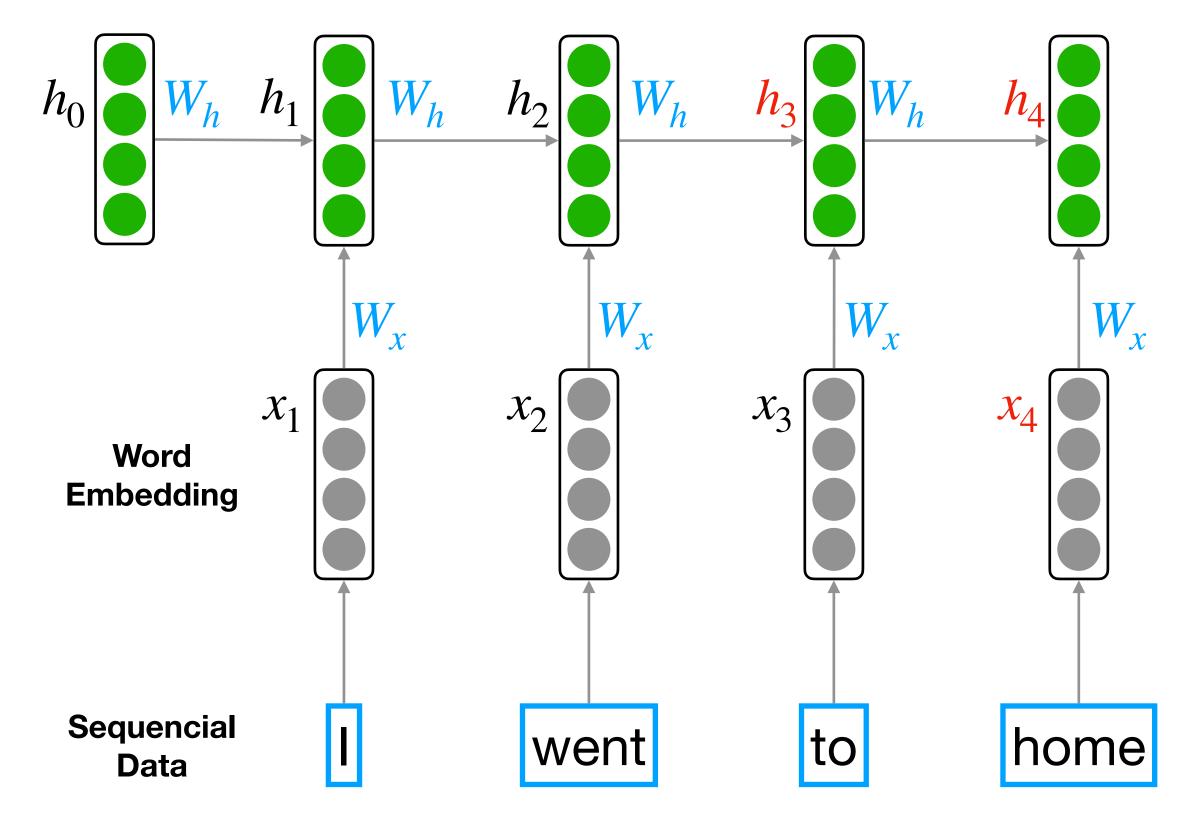
$$h_t = tanh(W_h h_{t-1} + W_x x_t + b)$$

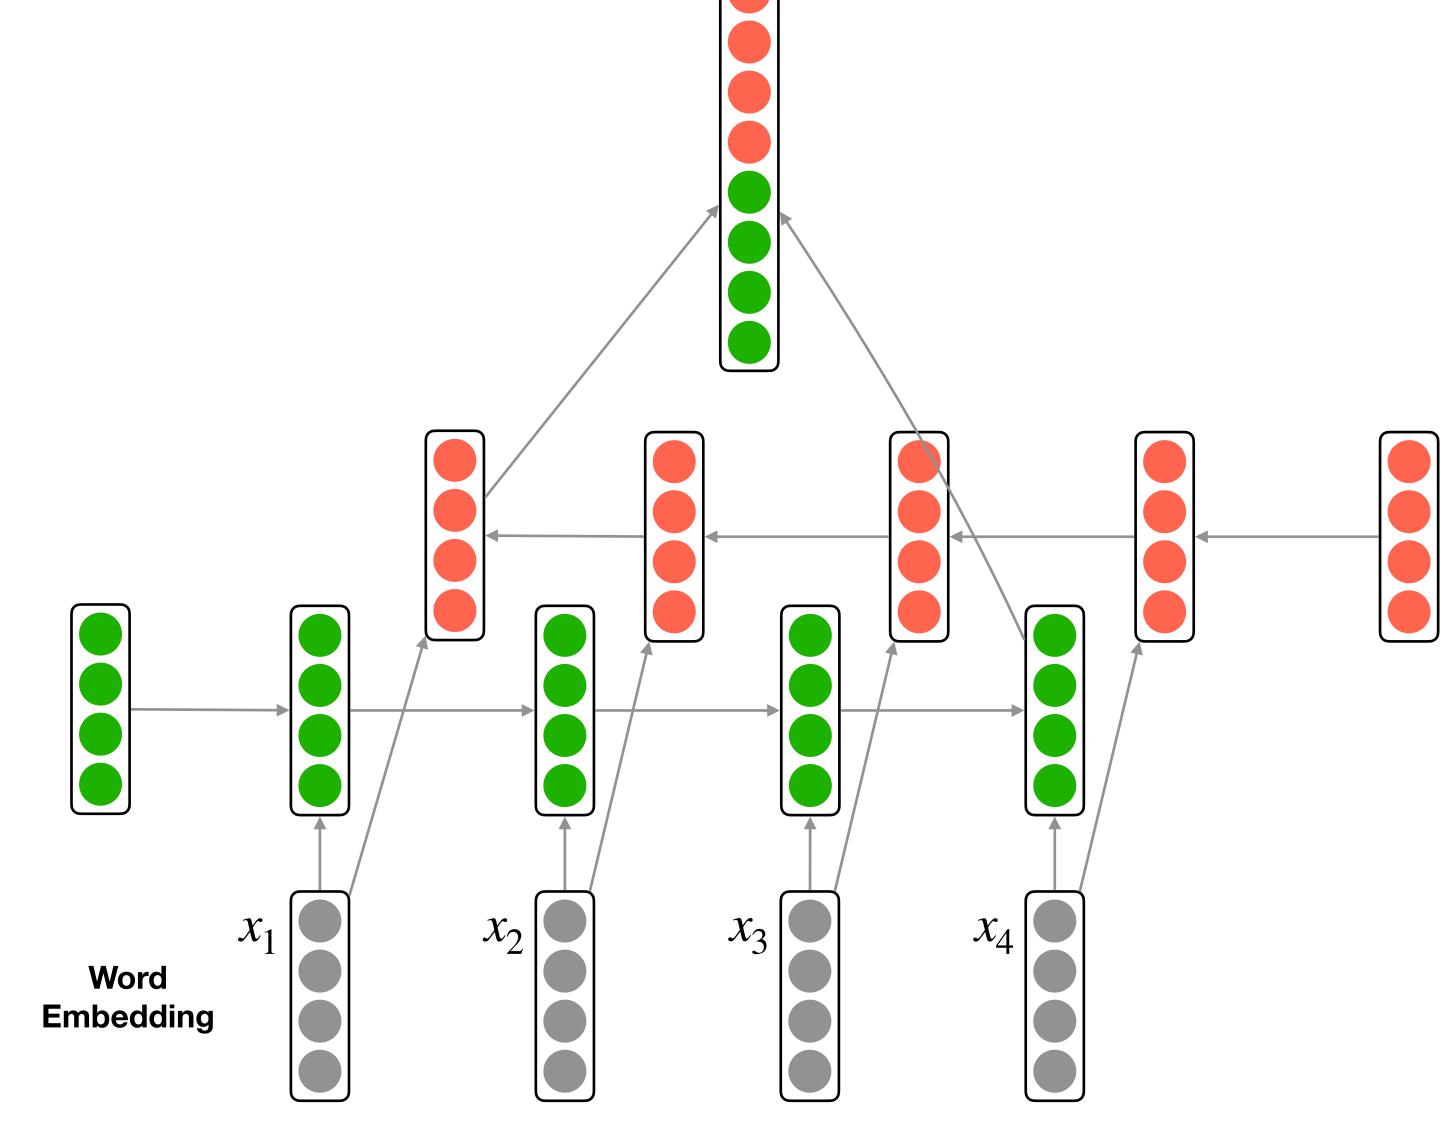




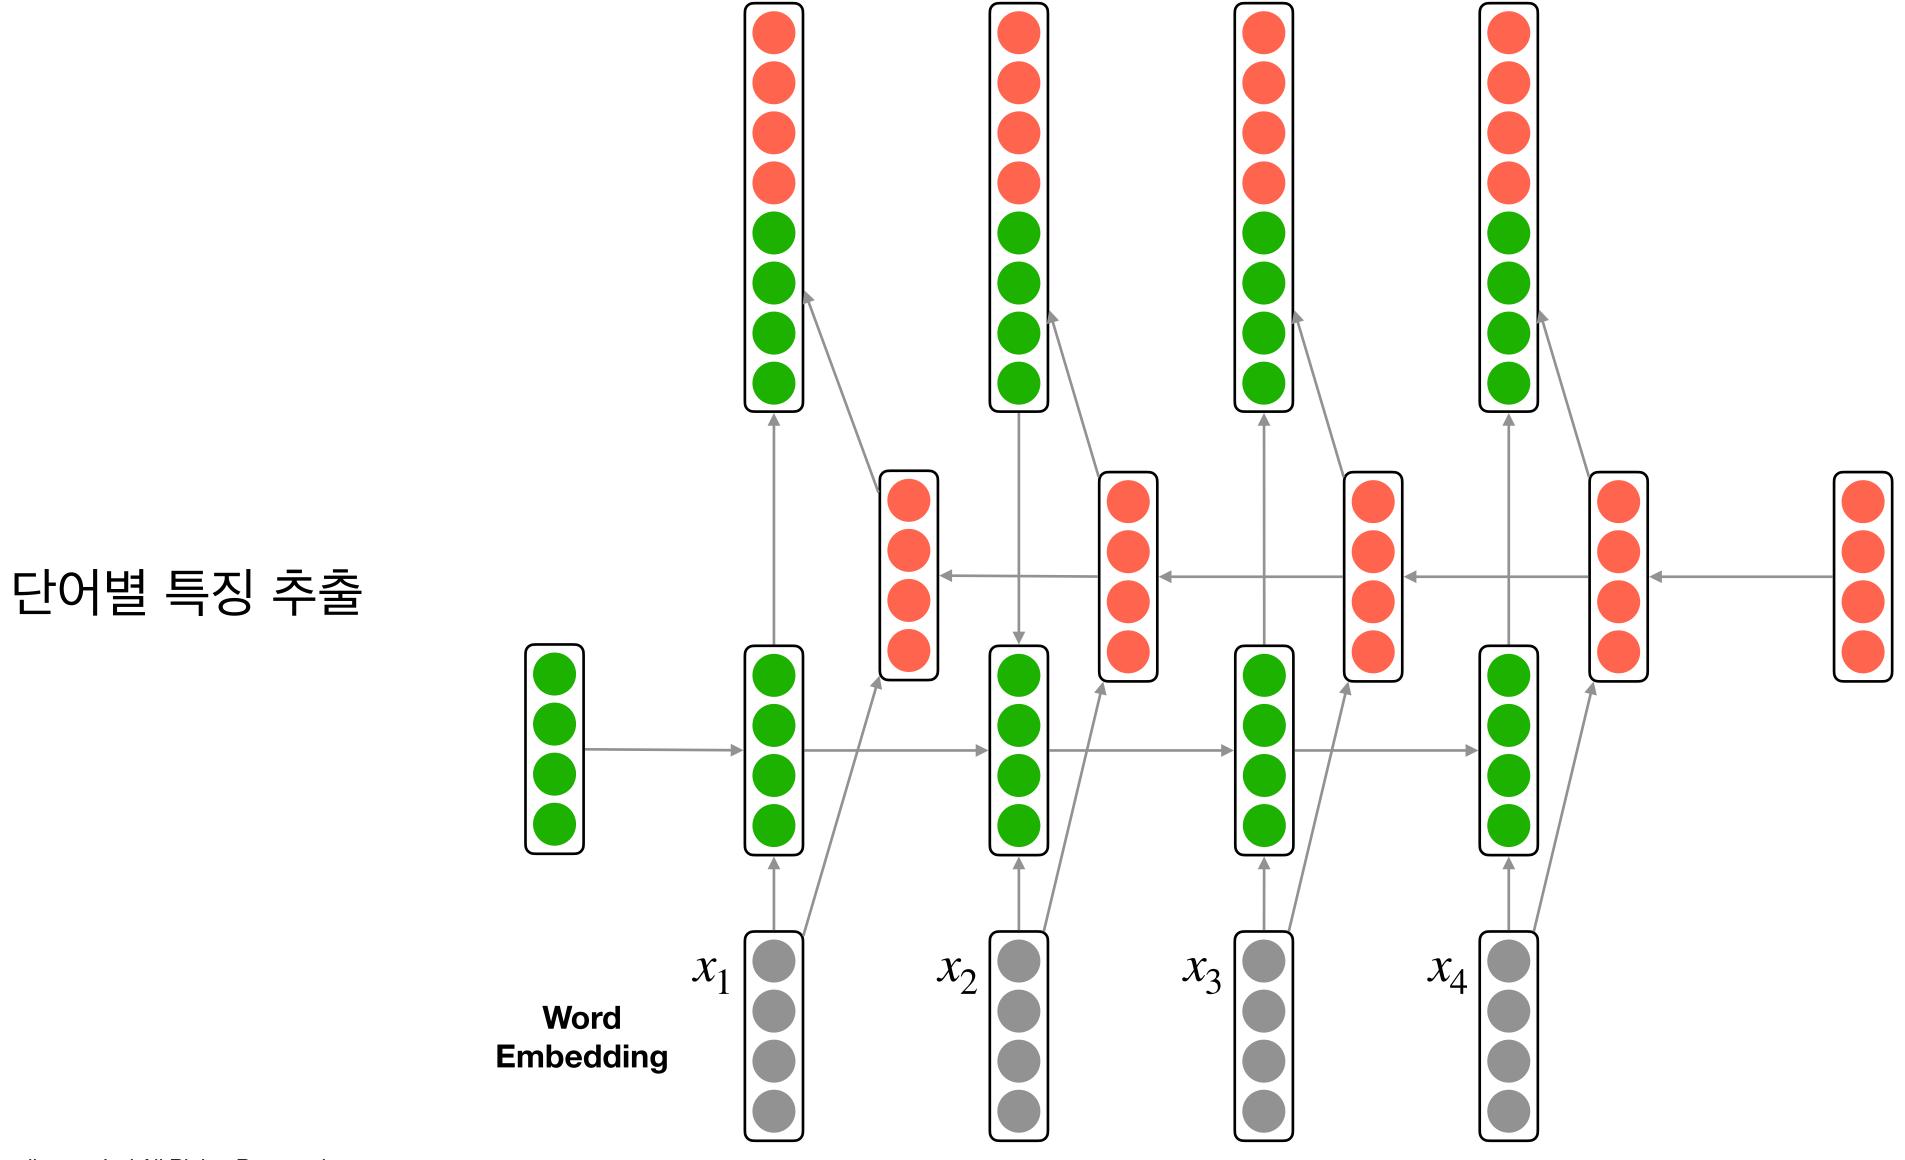
$$h_t = tanh(W_h h_{t-1} + W_x x_t + b)$$



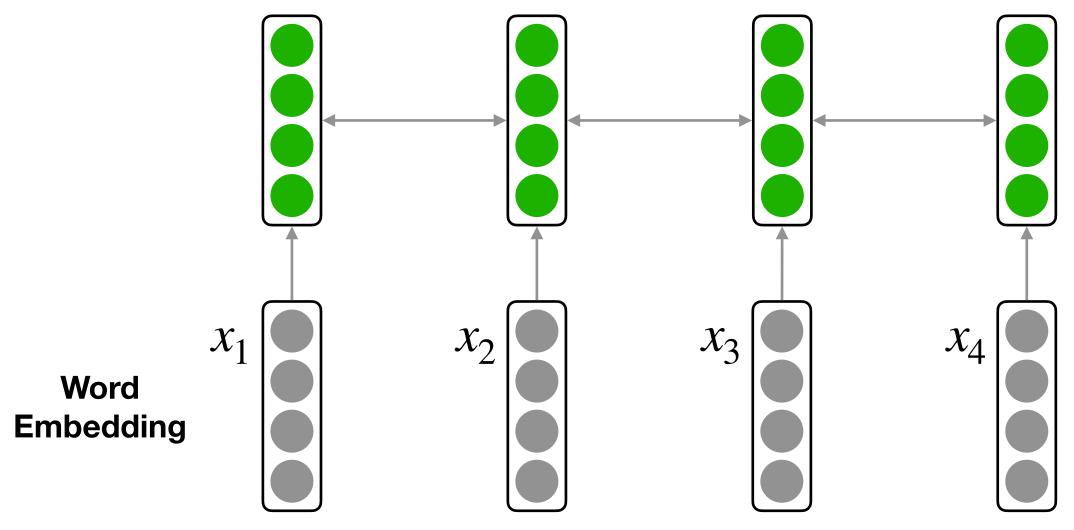




문장의 특징 추출



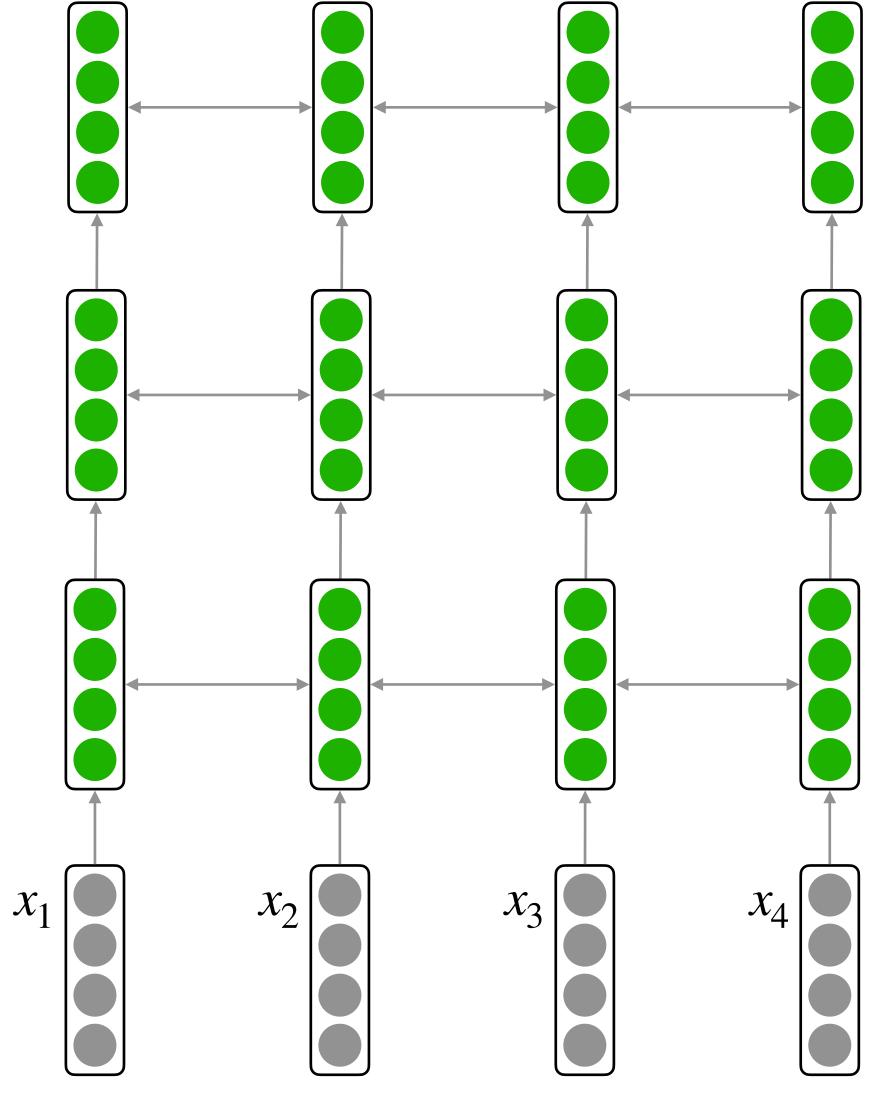
#### 간단한 표현



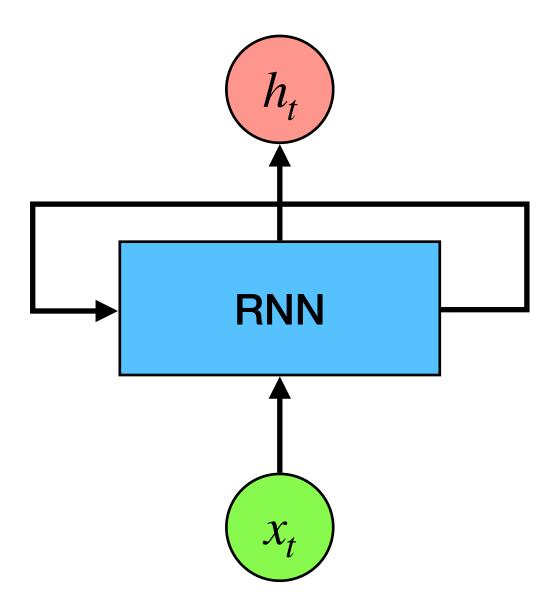
Word

**Embedding** 

Multi layer stack

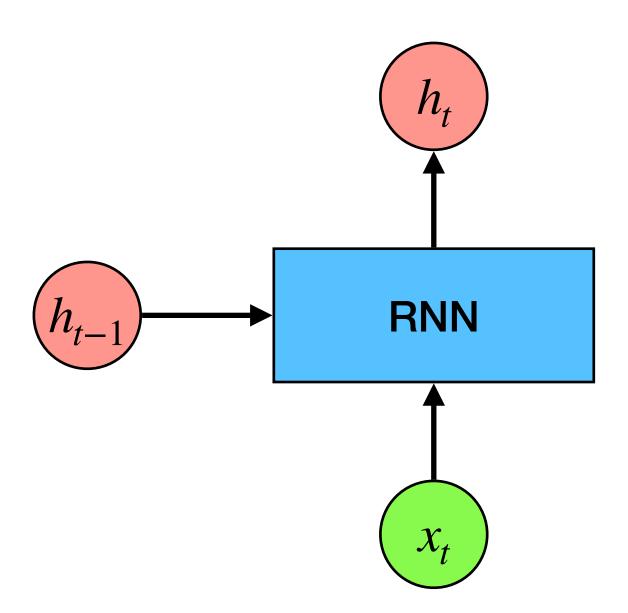


- 길이에 상관이 없음
- 순서대로 처리해야 하므로 느림
- 오랜 과거의 정보를 접근하기 어려움
- Vanishing gradient problem
- Exploding gradient problem



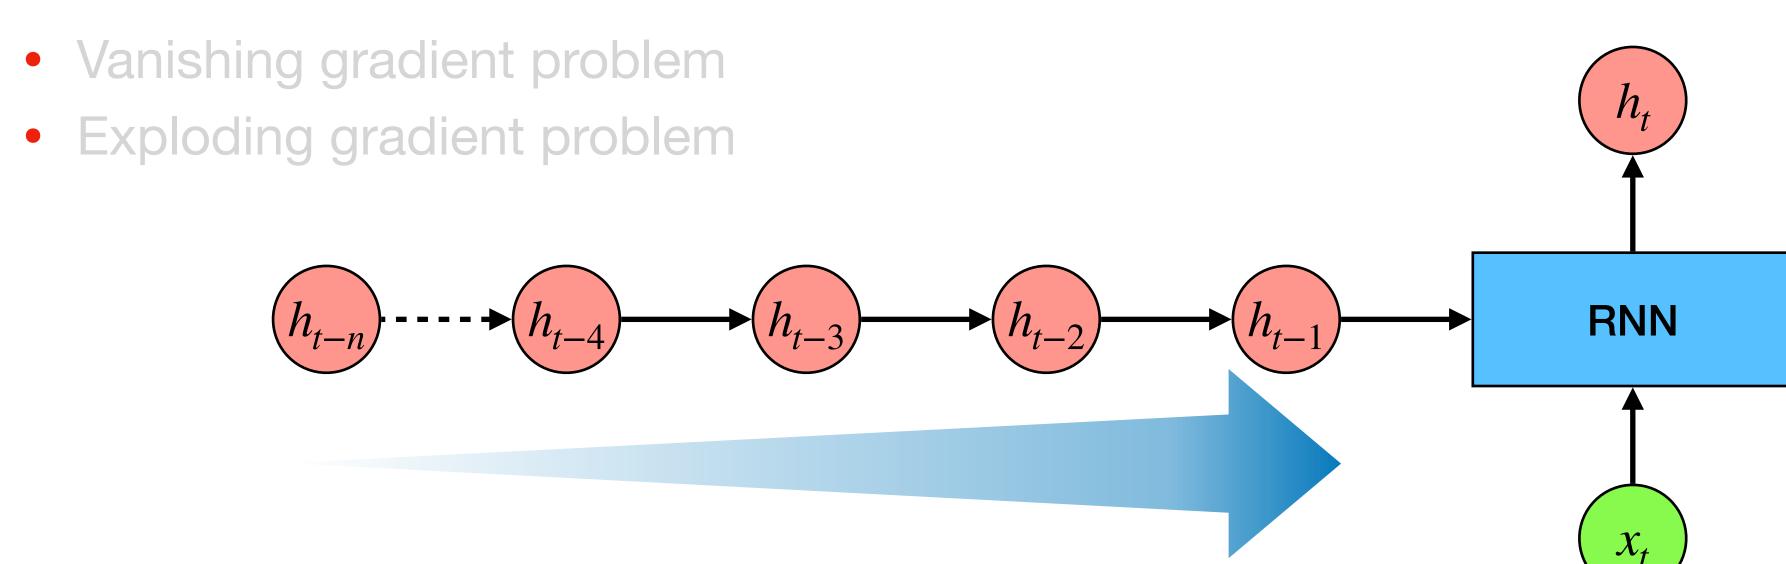
#### RNN 네트워크를 재귀적으로 사용하므로 길이에 상관 없음

- 길이에 상관이 없음
- 순서대로 처리해야 하므로 느림
- 오랜 과거의 정보를 접근하기 어려움
- Vanishing gradient problem
- Exploding gradient problem



## $h_t$ 를 계산하기 위해서는 $h_{t-1}$ 이 필요해서 병렬처리 불가

- 길이에 상관이 없음
- 순서대로 처리해야 하므로 느림
- 오랜 과거의 정보를 접근하기 어려움

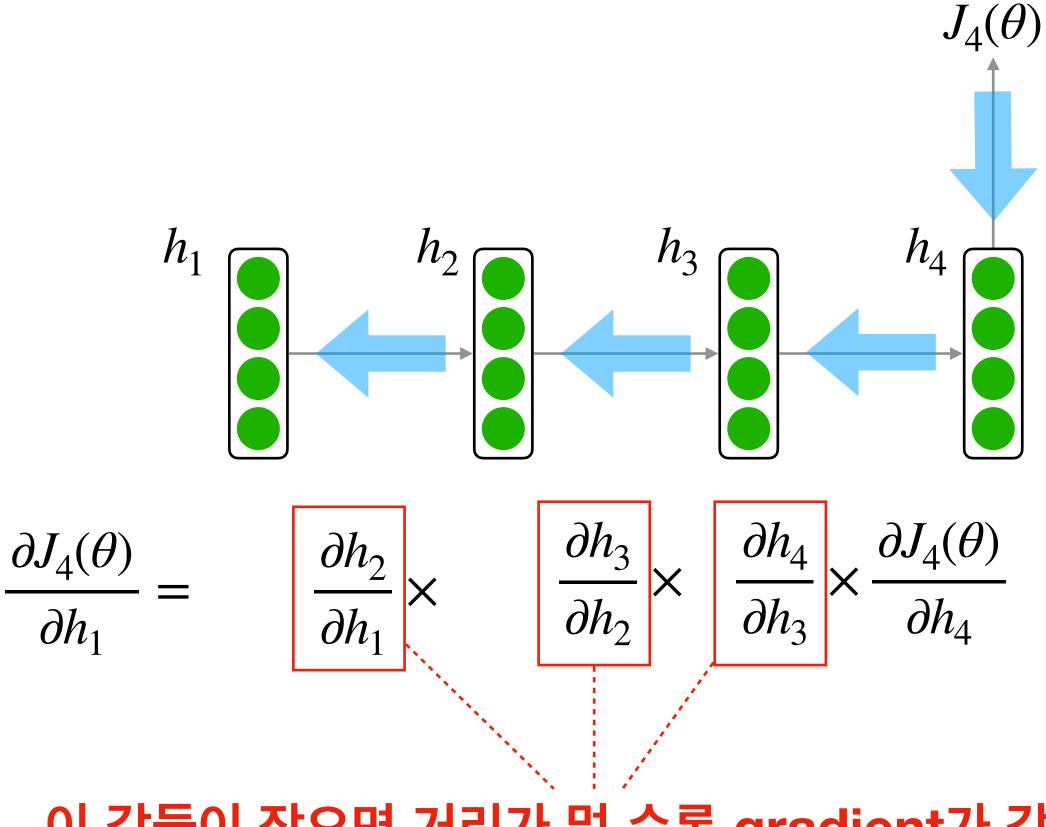


## $h_t$ 는최근 정보가 강하고 과거의 정보는 점차 약해짐

- 길이에 상관이 없음
- 순서대로 처리해야 하므로 느림
- 오랜 과거의 정보를 접근하기 어려움
- Vanishing gradient problem
- Exploding gradient problem

**Chain rule!** 

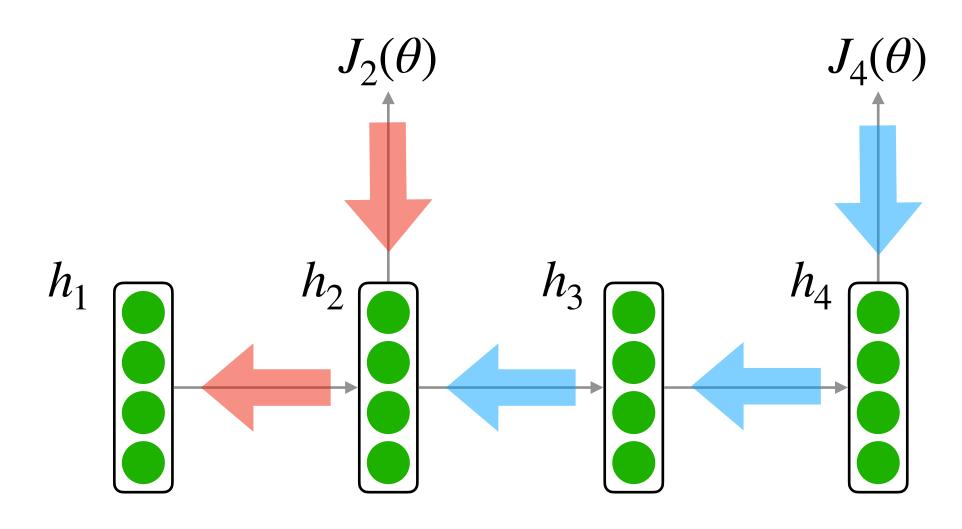
$$h_t = tanh(W_h h_{t-1} + W_x x_t + b)$$



이 값들이 작으면 거리가 멀 수록 gradient가 감소함

- 길이에 상관이 없음
- 순서대로 처리해야 하므로 느림
- 오랜 과거의 정보를 접근하기 어려움
- Vanishing gradient problem
- Exploding gradient problem

$$h_t = tanh(W_h h_{t-1} + W_x x_t + b)$$

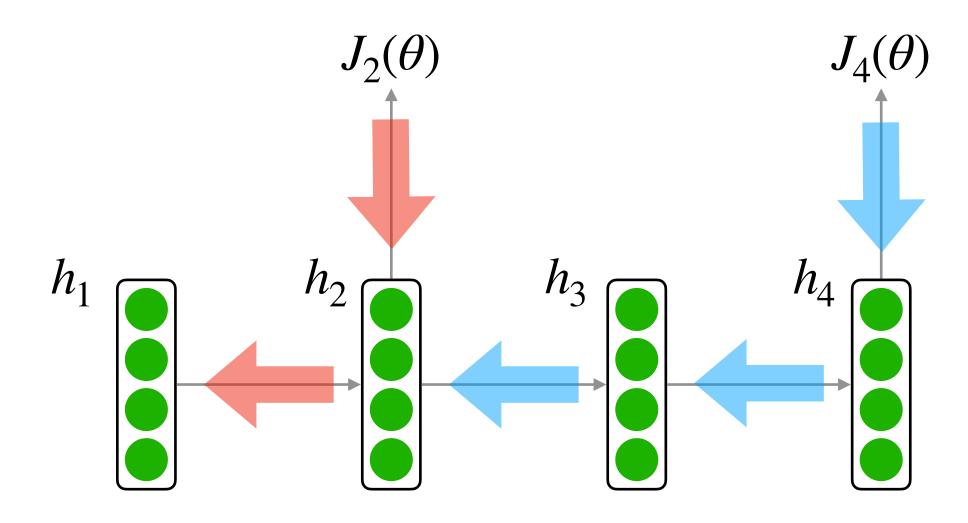


먼 거리의 gradient는 사라지고 가까운 거리의 gradient만 영향을 받음

19

- 길이에 상관이 없음
- 순서대로 처리해야 하므로 느림
- 오랜 과거의 정보를 접근하기 어려움
- Vanishing gradient problem
- Exploding gradient problem

$$h_t = tanh(W_h h_{t-1} + W_x x_t + b)$$

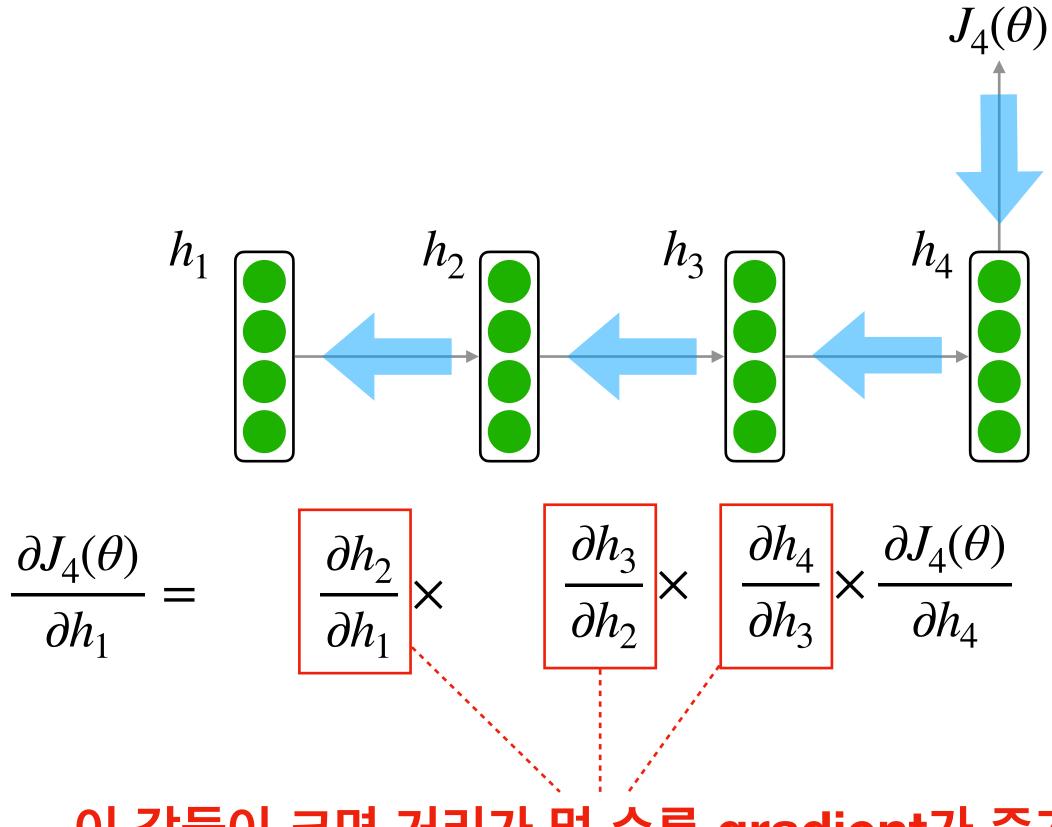




20

- 길이에 상관이 없음
- 순서대로 처리해야 하므로 느림
- 오랜 과거의 정보를 접근하기 어려움
- Vanishing gradient problem
- Exploding gradient problem

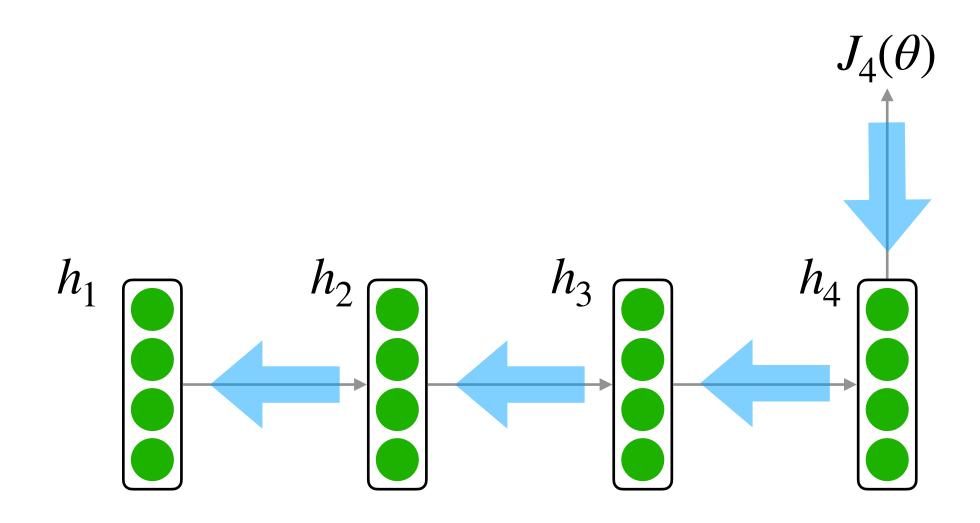
$$h_t = tanh(W_h h_{t-1} + W_x x_t + b)$$



이 값들이 크면 거리가 멀 수록 gradient가 증가함

- 길이에 상관이 없음
- 순서대로 처리해야 하므로 느림
- 오랜 과거의 정보를 접근하기 어려움
- Vanishing gradient problem
- Exploding gradient problem

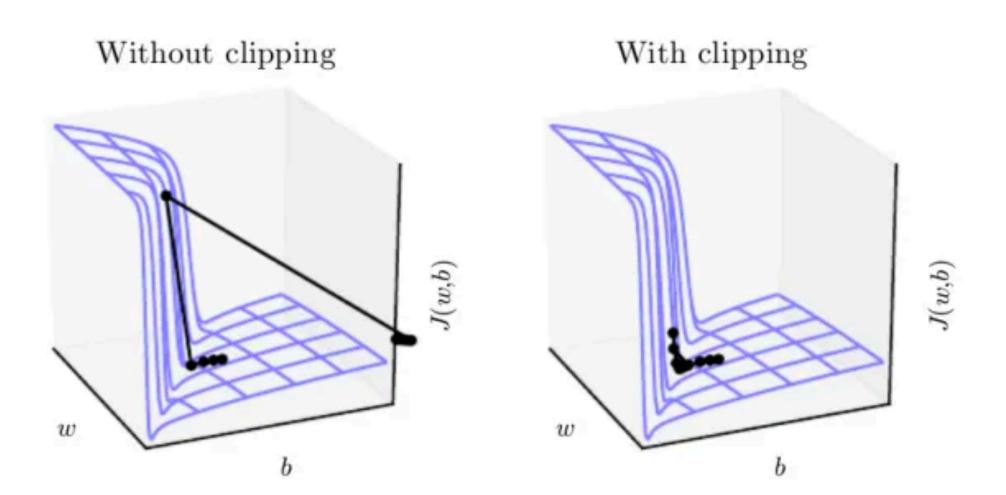
$$h_t = tanh(W_h h_{t-1} + W_x x_t + b)$$



학습이 잘 안되거나 Inf, NaN 등의 loss가 발생할 수 있음

22

- 길이에 상관이 없음
- 순서대로 처리해야 하므로 느림
- 오랜 과거의 정보를 접근하기 어려움
- Vanishing gradient problem
- Exploding gradient problem



**Algorithm 1** Pseudo-code for norm clipping the gradients whenever they explode

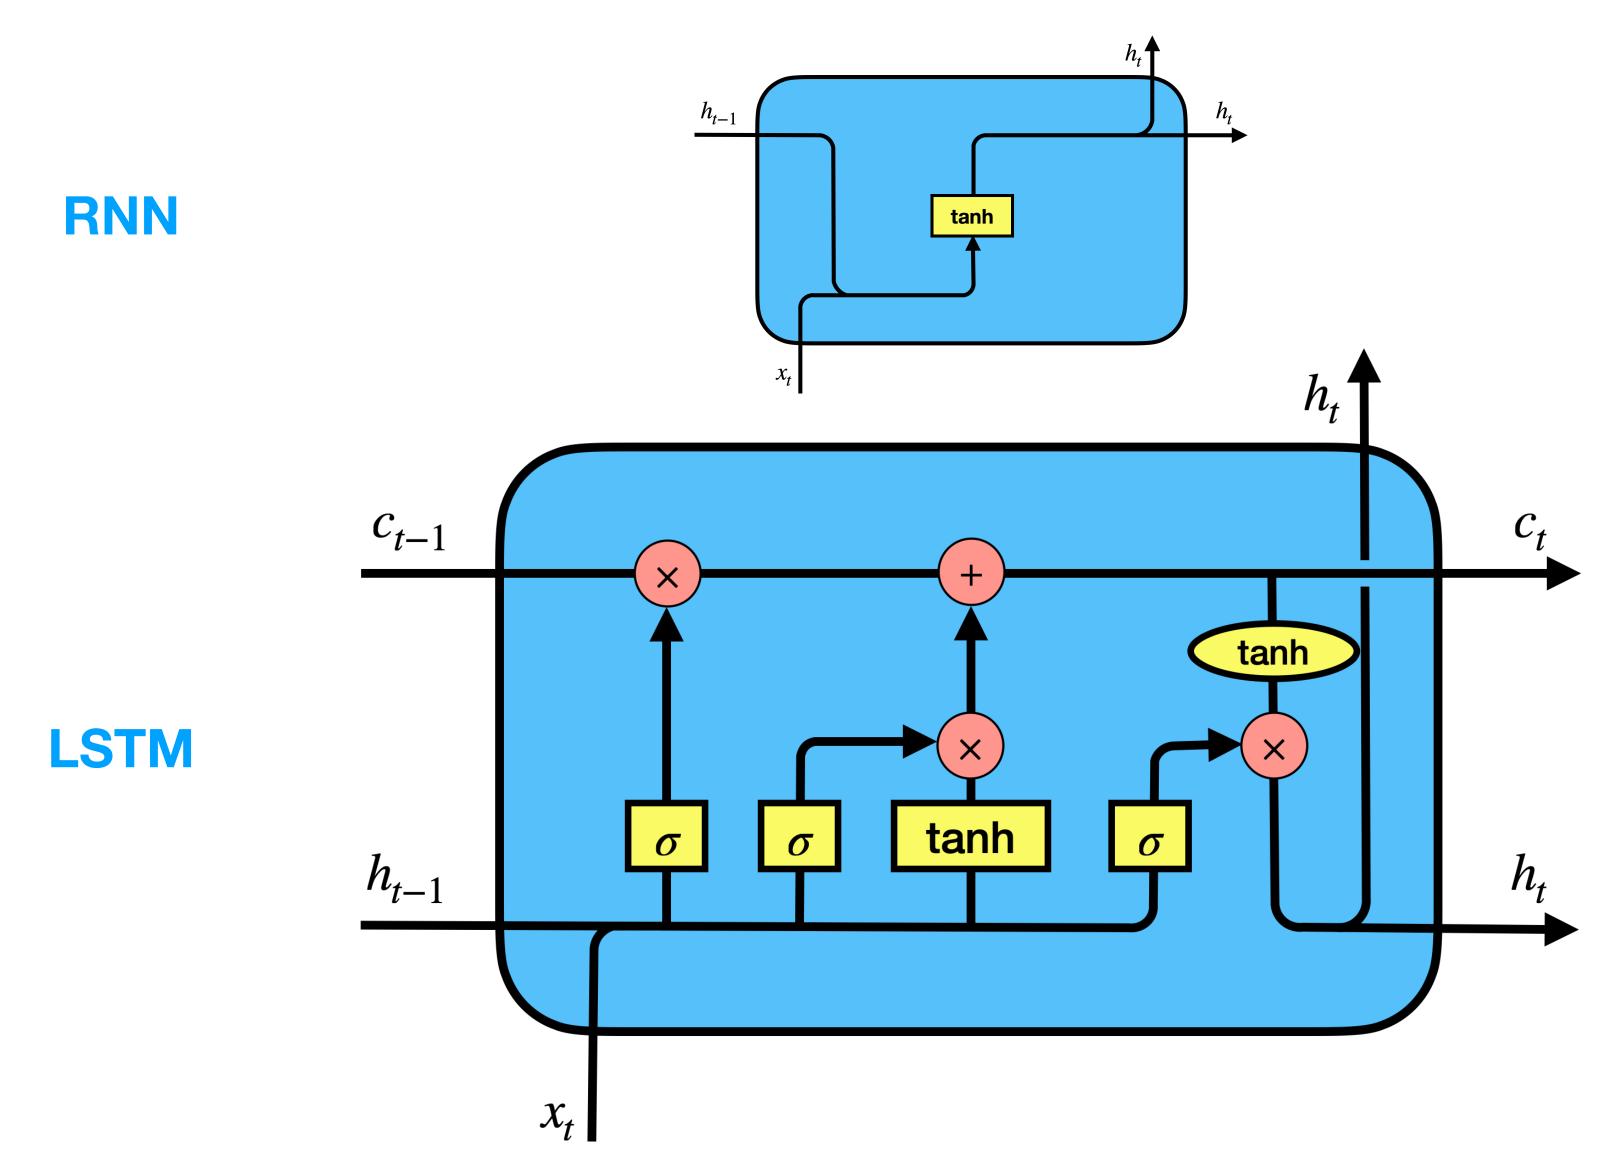
$$\hat{\mathbf{g}} \leftarrow \frac{\partial \mathcal{E}}{\partial \theta}$$

if  $\|\hat{\mathbf{g}}\| \geq threshold$  then

 $\hat{\mathbf{g}} \leftarrow \frac{threshold}{\|\hat{\mathbf{g}}\|} \hat{\mathbf{g}}$ 

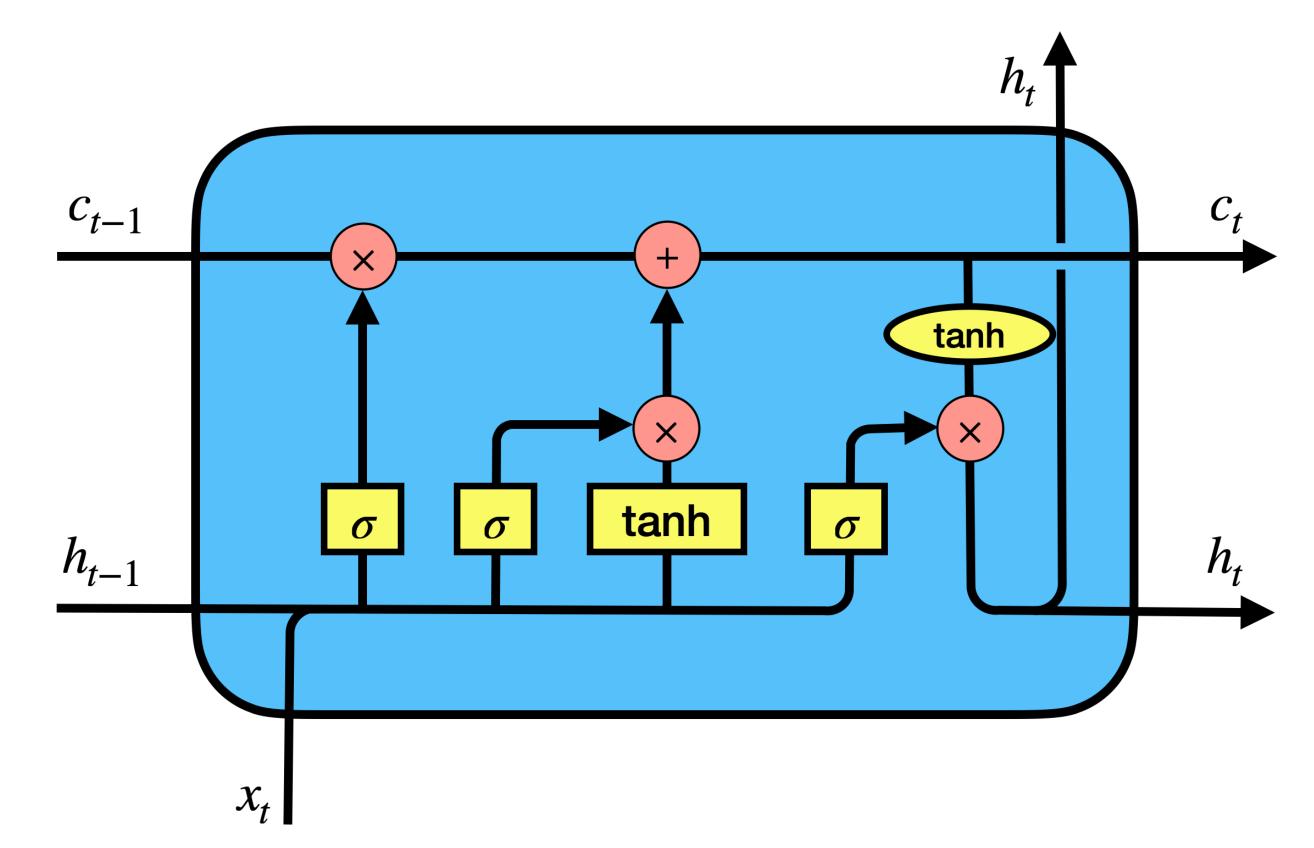
end if

# LSTM (Long-Short Term Memory)



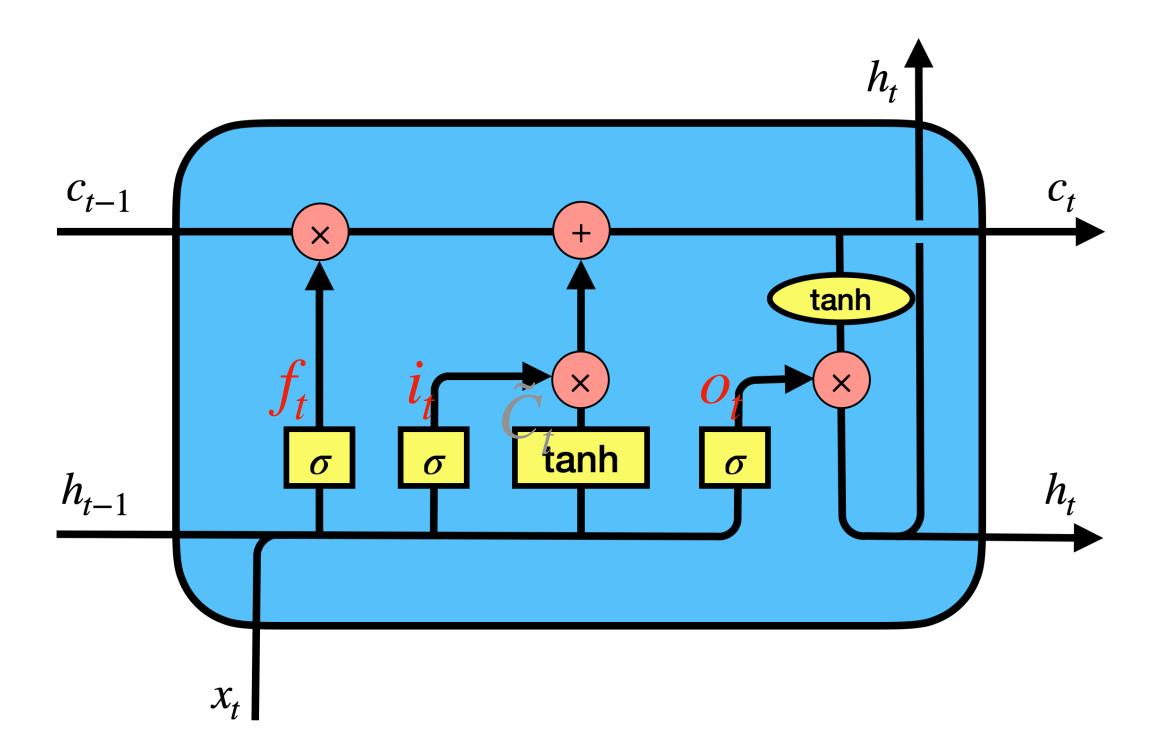
## What is LSTM

- RNN의 Vanishing gradient 문제를 해결하기 위한 모델
  - Memory cell을 추가 함 (long term state)
  - $c_t = c_{t-1} + function(h_{t-1}, x_t)$



# LSTM (gates)

- Forget Gate: 이전 step Memory cell의 정보를 얼마나 사용할지 결정
- Input Gate: 새로 계산된 Memory cell을 얼마나 사용할지 결정
- Output Gate: Memory cell값을 얼마만큼 사용할 것인지 결정



• 
$$f_t = \sigma(W_{hf}h_{t-1} + W_{xf}x_t + b_f)$$

• 
$$i_t = \sigma(W_{hi}h_{t-1} + W_{xi}x_t + b_i)$$

• 
$$o_t = \sigma(W_{ho}h_{t-1} + W_{xo}x_t + b_o)$$

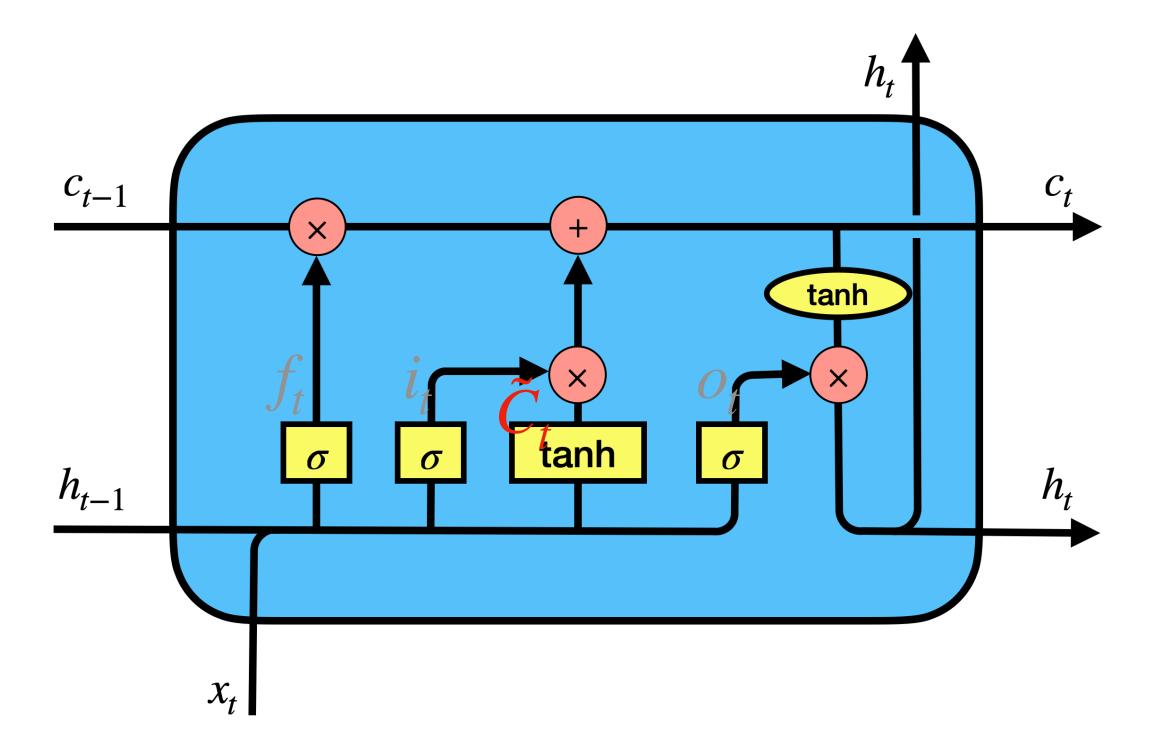
• 
$$\tilde{C}_t = tanh(W_{hc}h_{t-1} + W_{xc}x_t + b_c)$$

• 
$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t$$

•  $h_t = o_t \odot tanh(C_t)$ 

## LSTM (cell & hidden)

- New Cell Contents: 현재 시점의 Memory cell 값
- Cell State: 과거 Cell State와 현재 시점의 Cell Content의 합
- Hidden State: 현재 시점의 출력 값



• 
$$f_t = \sigma(W_{hf}h_{t-1} + W_{xf}x_t + b_f)$$

• 
$$i_t = \sigma(W_{hi}h_{t-1} + W_{xi}x_t + b_i)$$

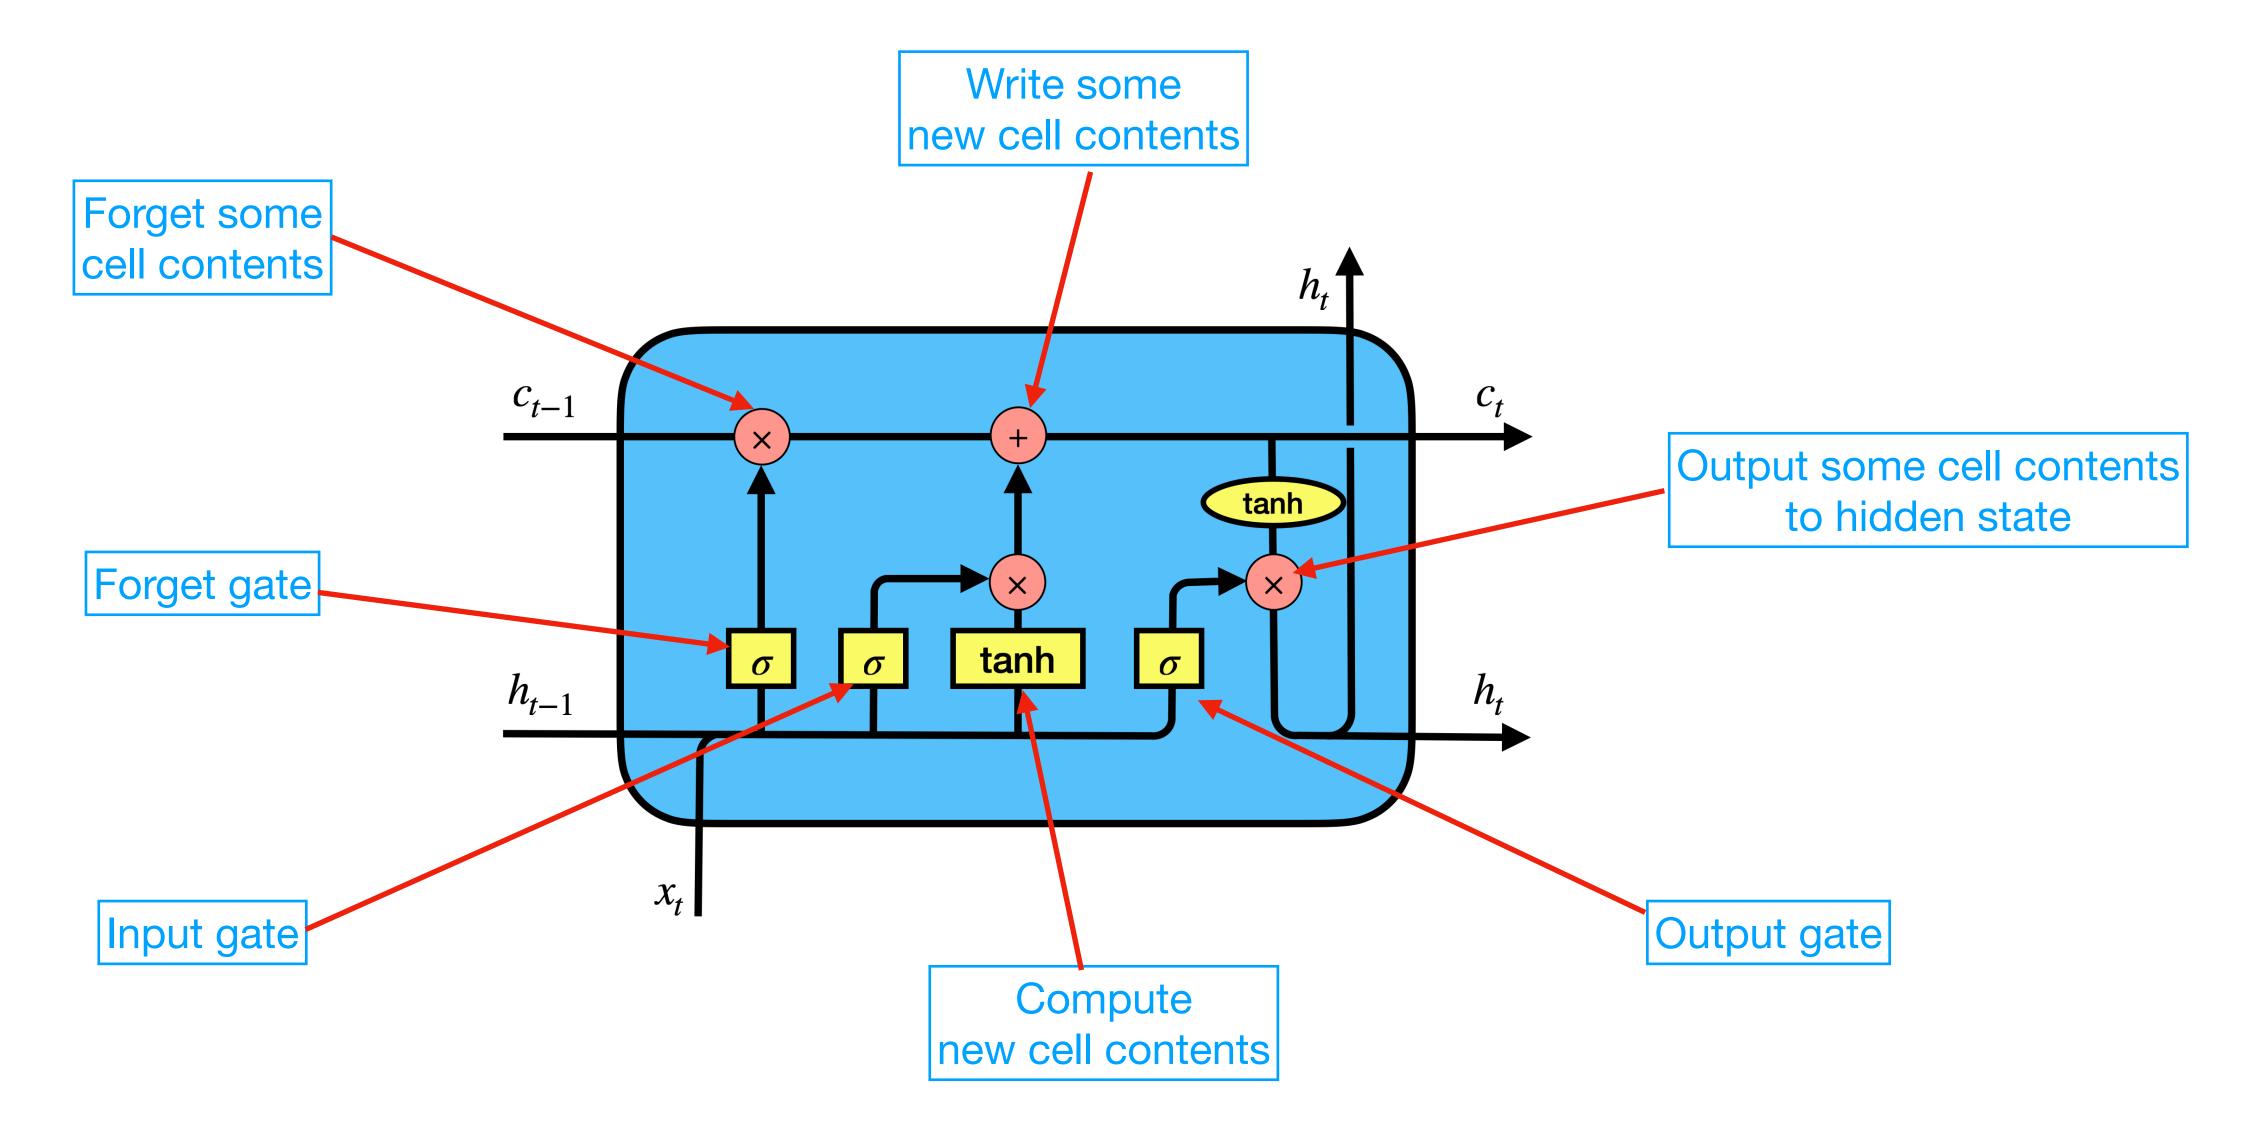
• 
$$o_t = \sigma(W_{ho}h_{t-1} + W_{xo}x_t + b_o)$$

• 
$$\tilde{C}_t = tanh(W_{hc}h_{t-1} + W_{xc}x_t + b_c)$$

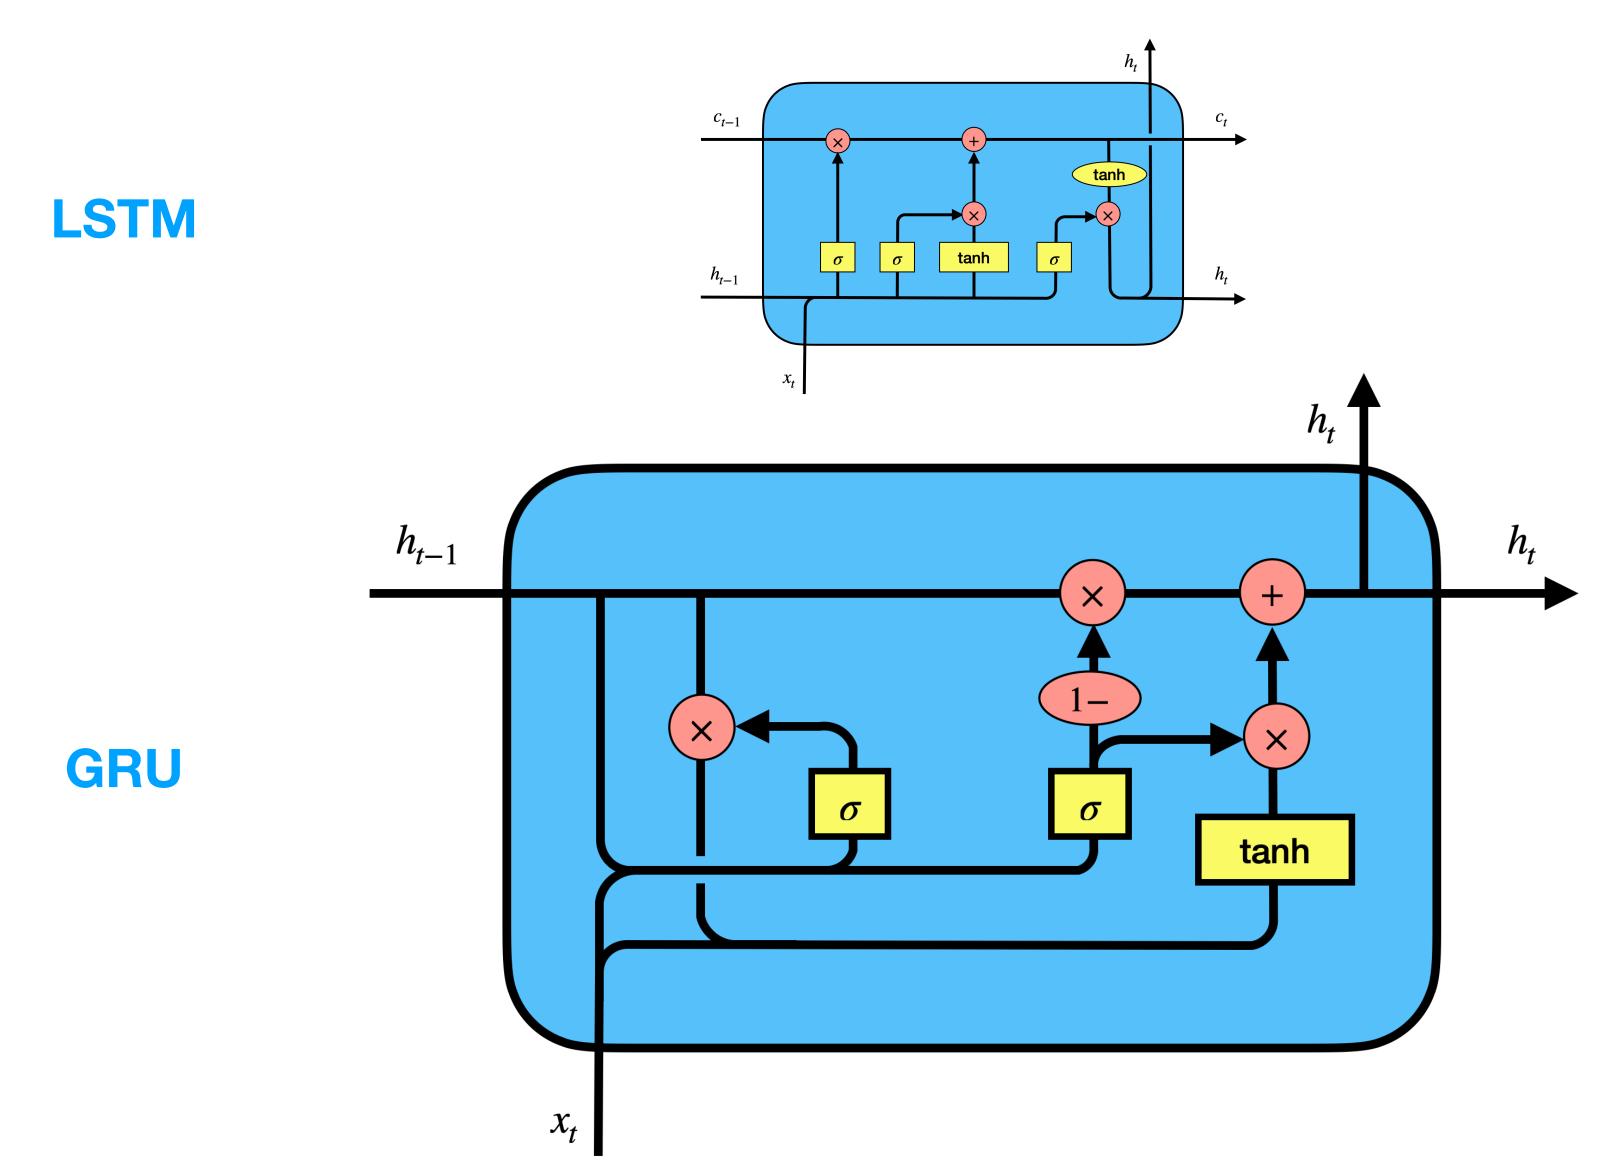
• 
$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t$$

•  $h_t = o_t \odot tanh(C_t)$ 

## **LSTM**

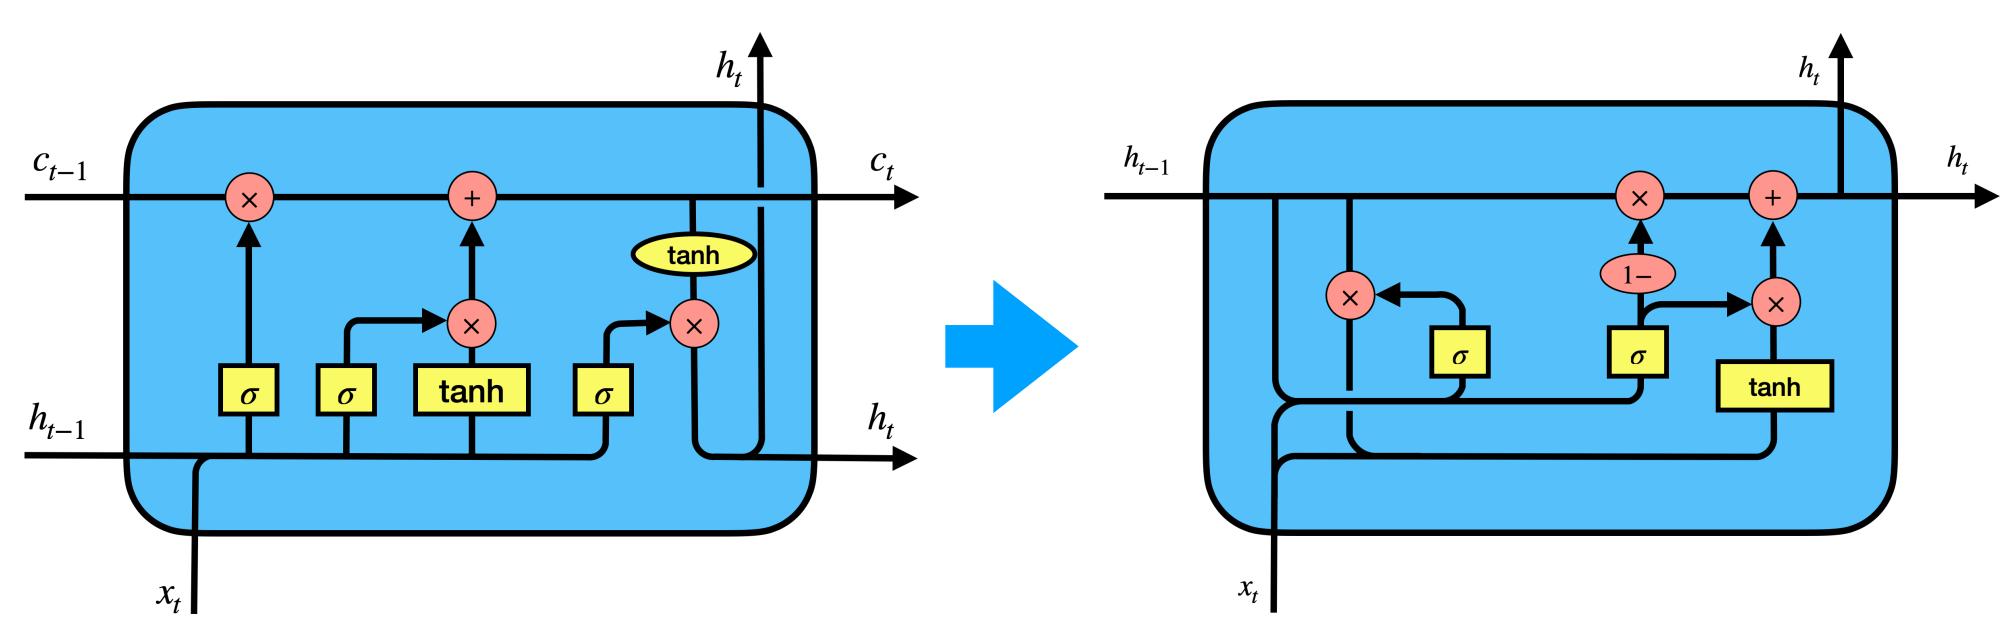


# GRU (Gated Recurrent Unit)



## What is GRU

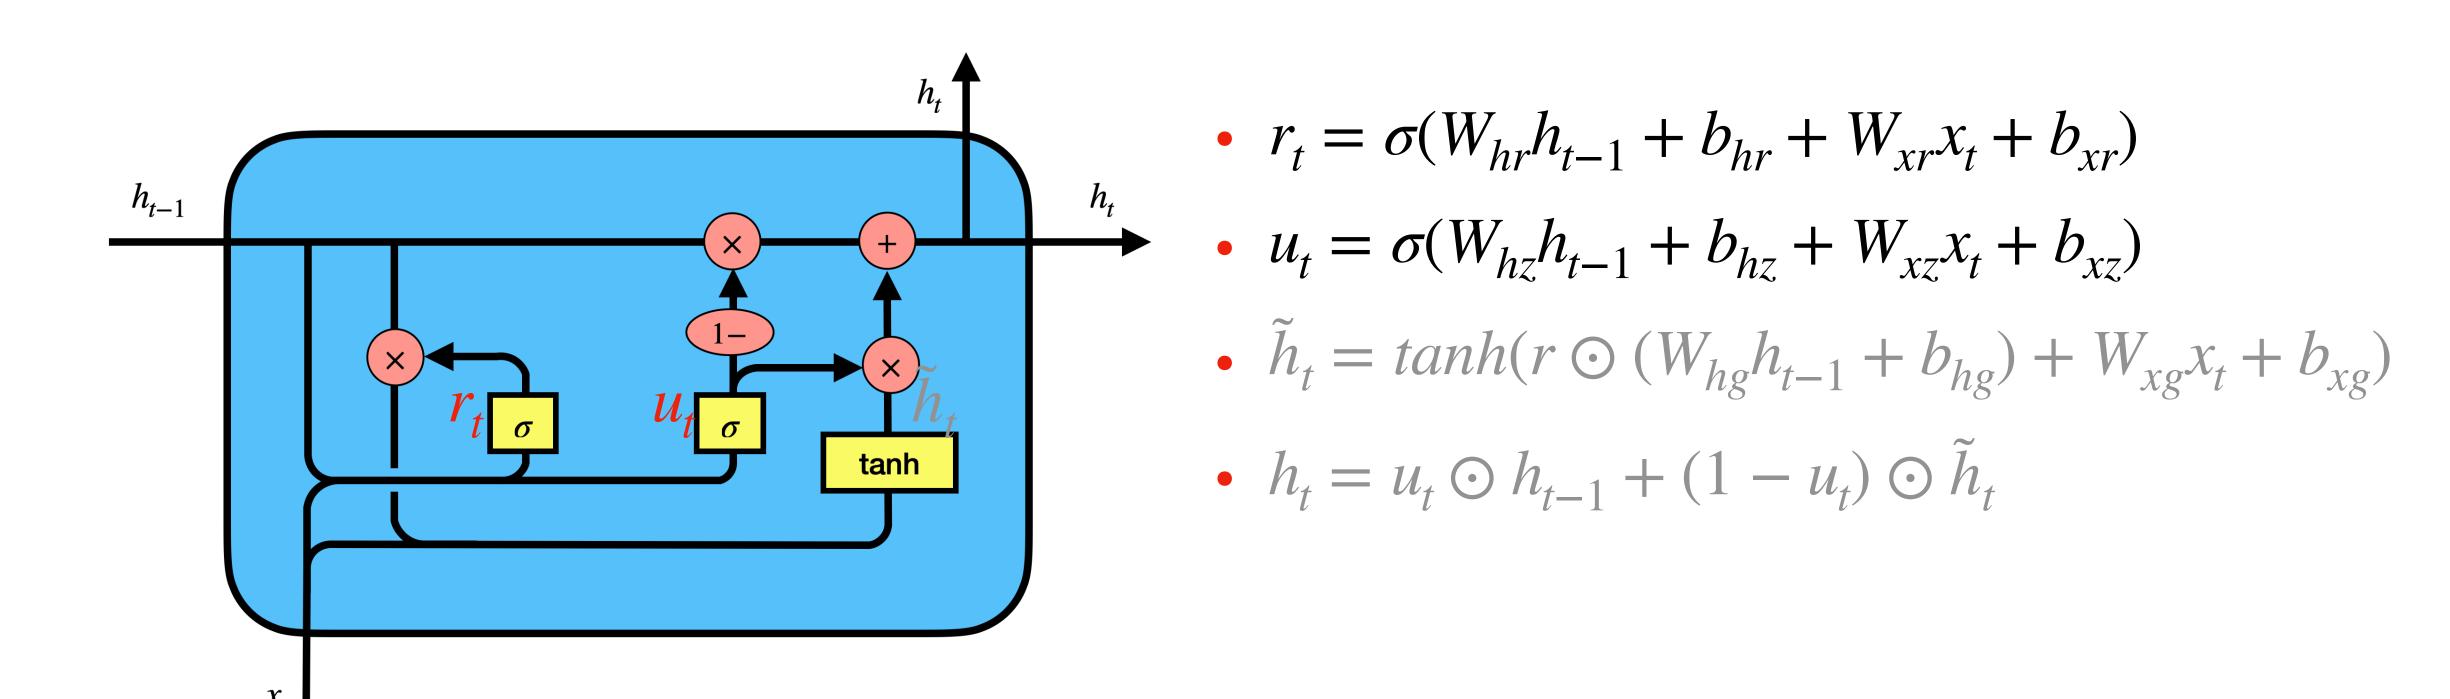
- LSTM보다 단순한 구조 이면서도 긴 데이터를 잘 처리함
  - Memory cell을 사용 안함
  - Gate 숫자를 2개로 줄임



30

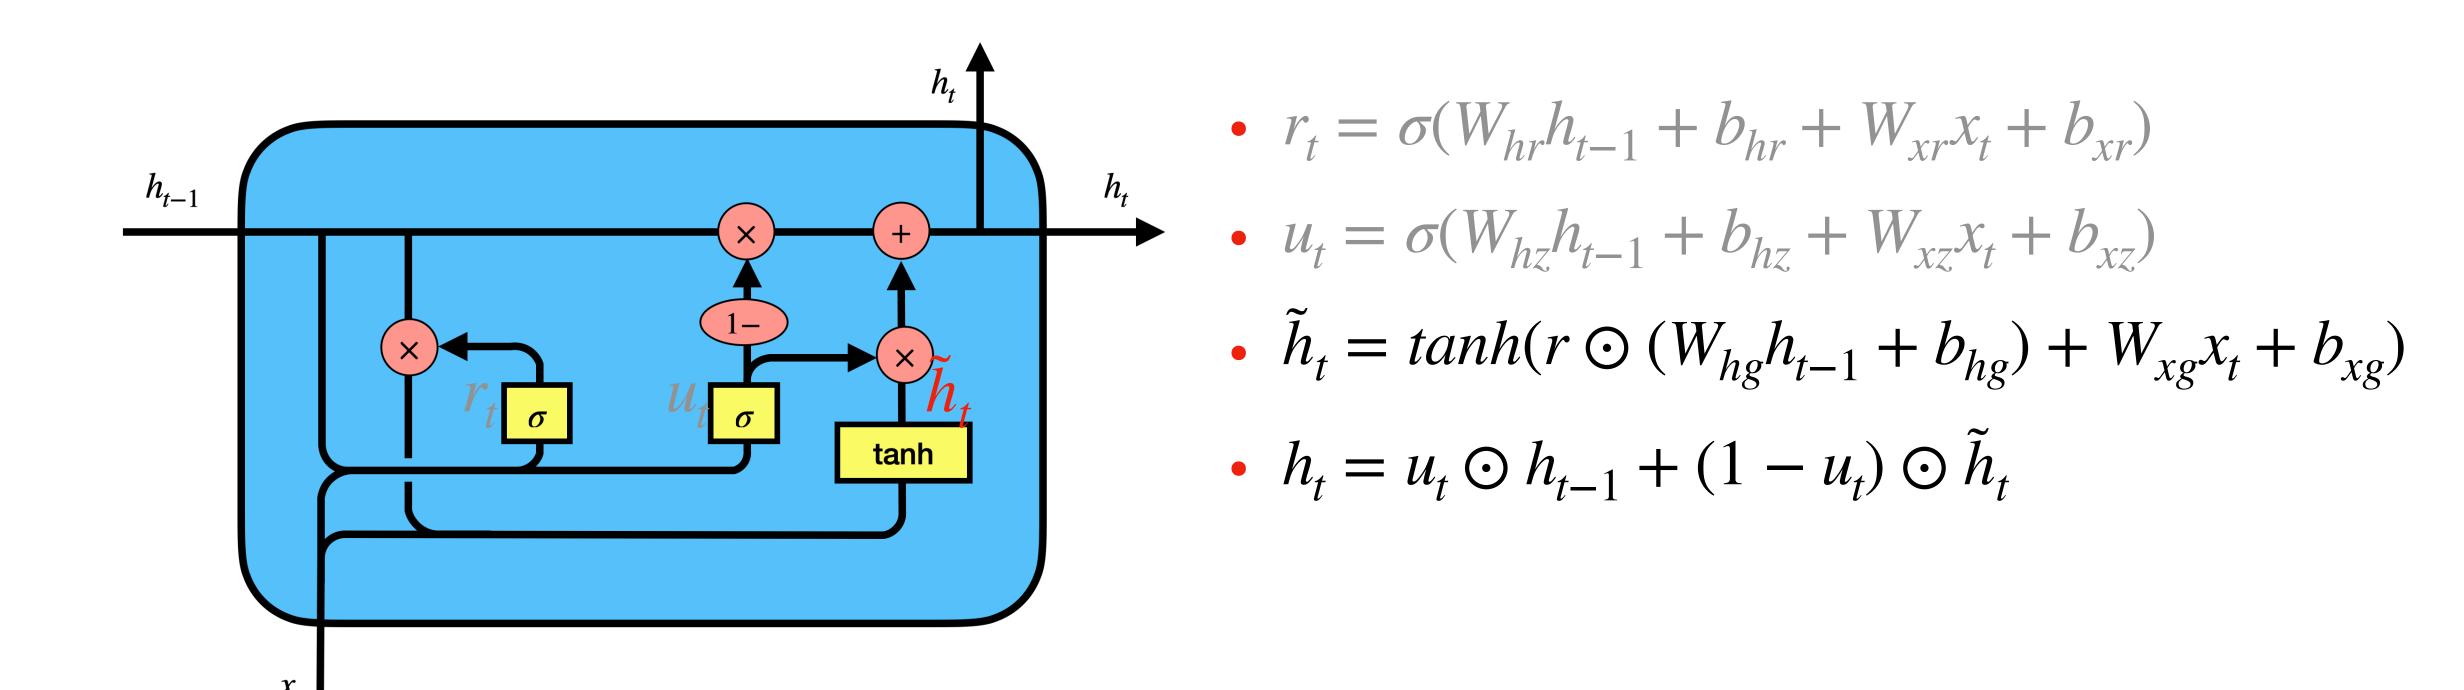
# GRU (gates)

- Reset Gate: 이전 시점  $h_{t-1}$ 의 정보를 얼마나 사용할지 결정
- Update Gate: 현재 시점의  $\tilde{h}_t$ 의 정보를 얼마나 사용할지 결정

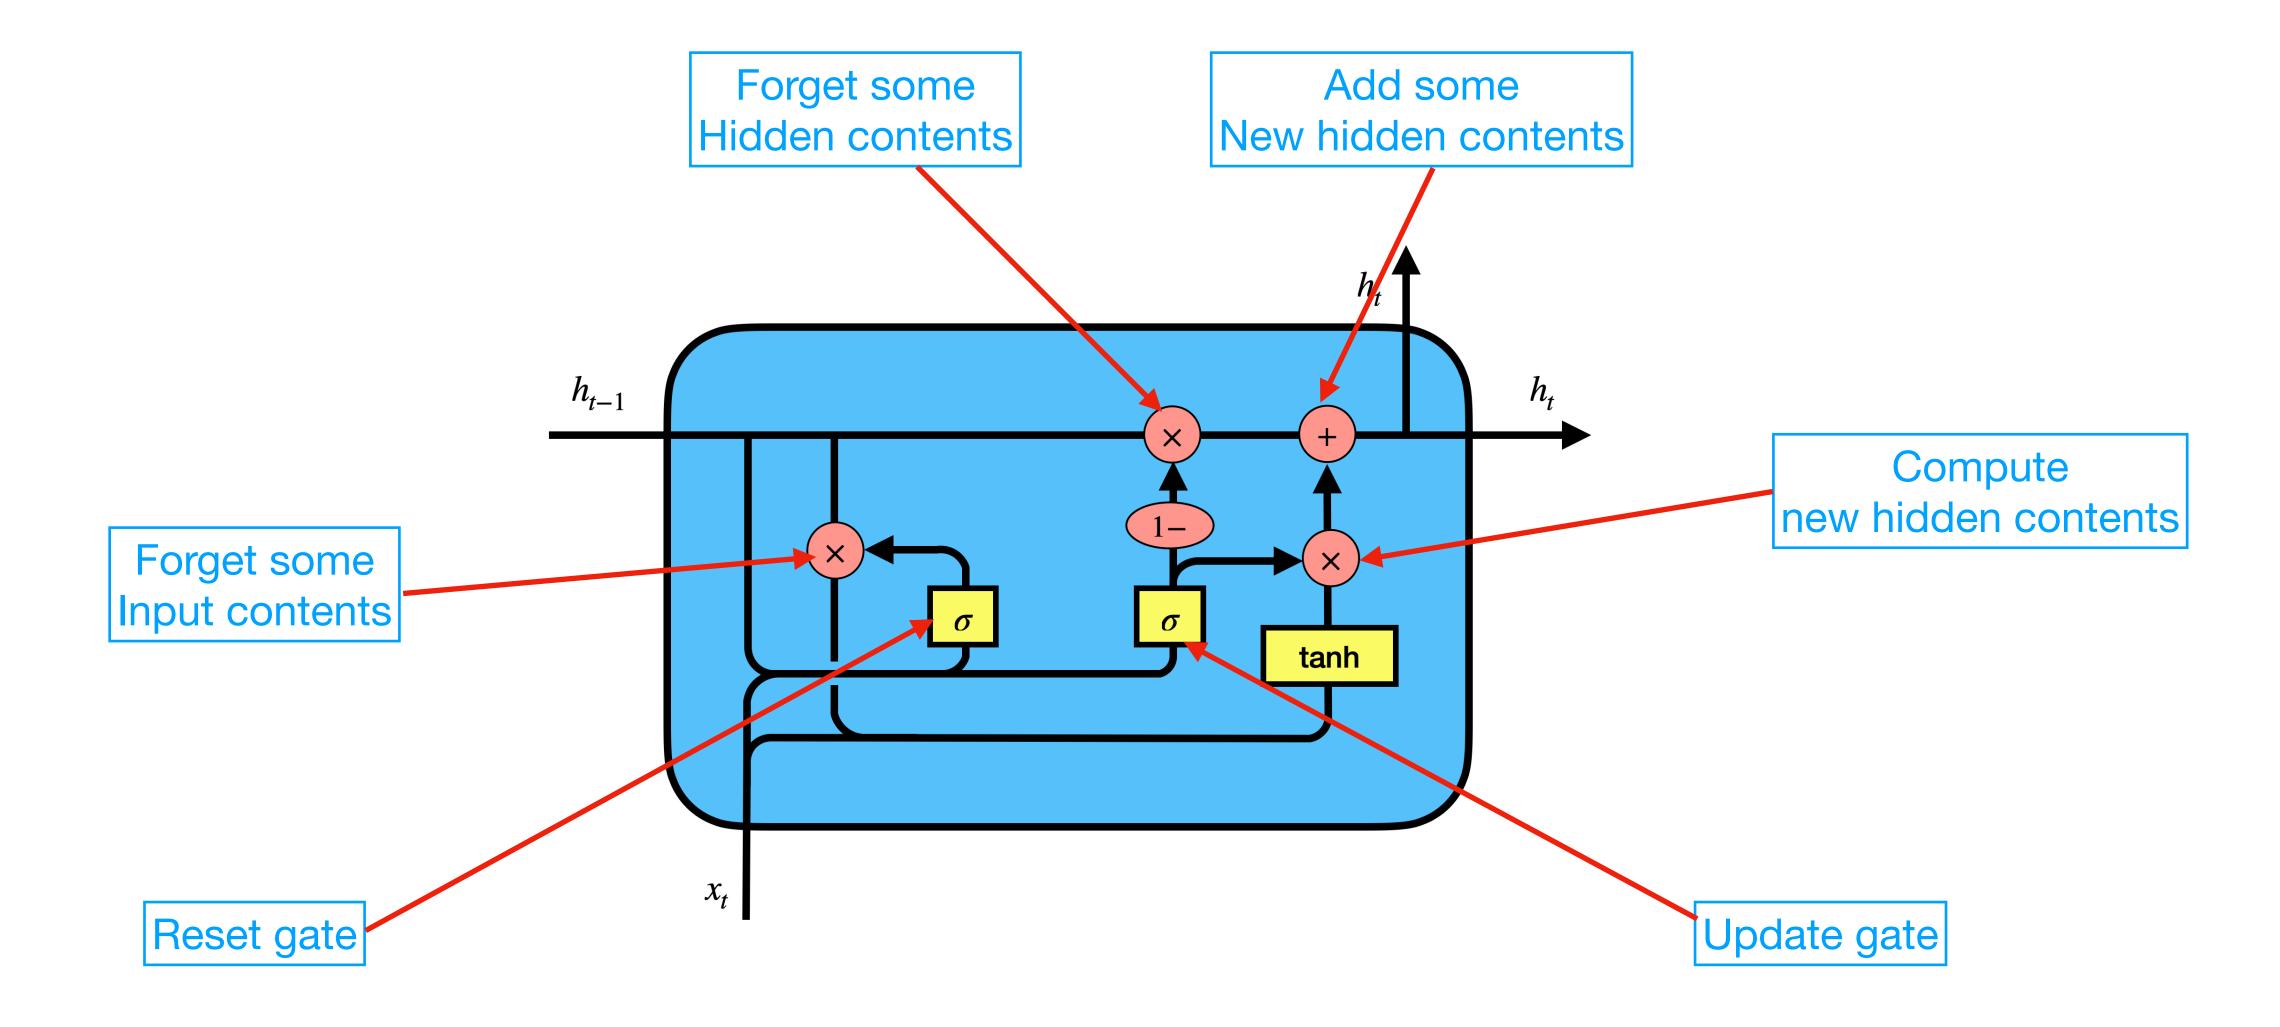


## GRU (hidden)

- New Hidden content: 현재 시점의 Hidden state 값
- Hidden state: 현재 시점의 출력 값



## GRU



# 감사합니다.