삼성전기 AI전문가 양성과정 - 프로젝트 실습 (비영상)

# 자연어처리를 위한 Text Similarity

현청천

2022.02.28

• 두 쌍의 text의 유사성을 예측하는 Task

한 남자가 음식을 먹고 있다. 한 남자가 뭔가를 먹고 있다.



같은 의미

한 비행기가 착륙하고 있다.

애니메이션화된 비행기 하나가 착륙하고 있다. 같은 의미



한 여성이 고기를 요리하고 있다. 한 남자가 말하고 있다.



다른 의미

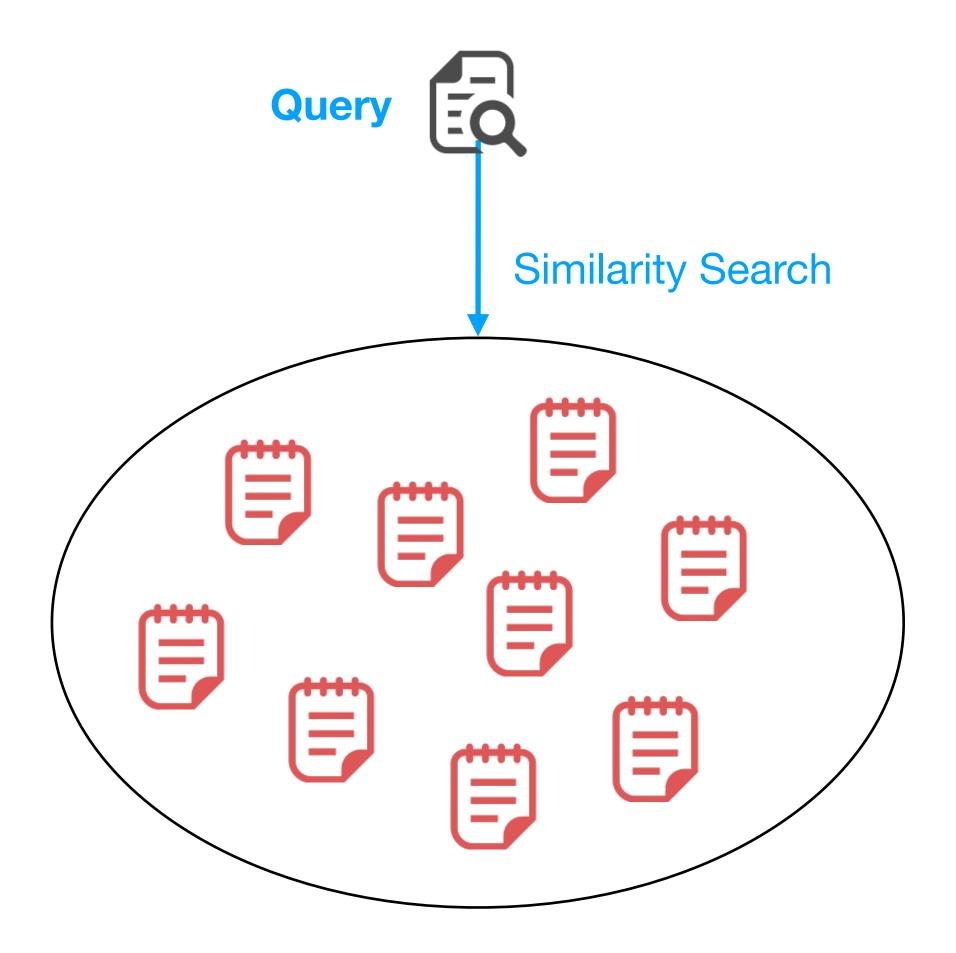
• 두 쌍의 text의 유사성을 예측하는 Task

한 남자가 음식을 먹고 있다. 한 남자가 뭔가를 먹고 있다. 4.2

한 비행기가 착륙하고 있다. 애니메이션화된 비행기 하나가 착륙하고 있다. 2.8

한 여성이 고기를 요리하고 있다. 한 남자가 말하고 있다. 0.0

- 두 쌍의 text의 유사성을 예측하는 Task
  - Information Retrieval (Search Engine)



- 두 쌍의 text의 유사성을 예측하는 Task
  - Information Retrieval (Search Engine)
  - Data Matching

특허

유(乳)제품; 분유 또는 분유제품; 보관; 쵸콜렛 우유; 아이스크림 또는 아이스크림을 조제하기 위 한 혼합물; 푸딩 또는 분말푸딩

#### 말 및 양 사육업

각종 용도의 말, 양 및 염 소를 사육하는 산업활동 을 말한다.

#### 젖소 사육업

우유를 생산하기 위하여 젖소를 사육하는 산업활 동을 말한다.

#### 양돈업

각종 용도의 돼지, 멧돼지 를 번식 및 사육하는 산업 활동을 말한다.

#### 내수면 어업

강, 호수, 하천 등 내수면 에서 어류 등의 각종 수 산 동.식물을 채취 또는 포획하는 산업활동을 말 한다.

#### 해수면 양식 어업

해수면 또는 육상에서 해수를 이용하여 각종 수산동.식물을 증식 또는 양식하는 산업활동을 말한다.

#### 철 광업

철 성분을 주로 함유하고 있는 각종 철광석을 채굴 하는 산업활동으로서 철 광석의 정광 및 기타 부수 적인 처리활동과 철광석 의 응집처리 활동도 포함 한다.

산업분류

#### Text Similarity

#### SentEval

Task	Туре	#train	#test	needs_train	set_classifier
MR	movie review	11k	11k	1	1
CR	product review	4k	4k	1	1
SUBJ	subjectivity status	10k	10k	1	1
MPQA	opinion-polarity	11k	11k	1	1
SST	binary sentiment analysis	67k	1.8k	1	1
SST	fine-grained sentiment analysis	8.5k	2.2k	1	1
TREC	question-type classification	6k	0.5k	1	1
SICK-E	natural language inference	4.5k	4.9k	1	1
SNLI	natural language inference	550k	9.8k	1	1
MRPC	paraphrase detection	4.1k	1.7k	1	1
STS 2012	semantic textual similarity	N/A	3.1k	0	0
STS 2013	semantic textual similarity	N/A	1.5k	0	0
STS 2014	semantic textual similarity	N/A	3.7k	0	0
STS 2015	semantic textual similarity	N/A	8.5k	0	0
STS 2016	semantic textual similarity	N/A	9.2k	0	0
STS B	semantic textual similarity	5.7k	1.4k	1	0
SICK-R	semantic textual similarity	4.5k	4.9k	1	0
coco	image-caption retrieval	567k	5*1k	1	0

- SentEval은 Sentence Embedding 품질을 평가하기위한 라이브러리
- 18개 중 STS12 ~ STS16, STSB, SICK-R
- 두 문장 간에 유사도 측정
- https://github.com/facebookresearch/SentEval

- Text Similarity
  - SentEval
  - Quora Question Pairs
  - Paired Question
  - KorSTS

- 질문 사이트인 Quora의 질문데이터
- 두 질문이 중복되는지 여부를 판단
- https://www.kaggle.com/c/quora-question-pairs

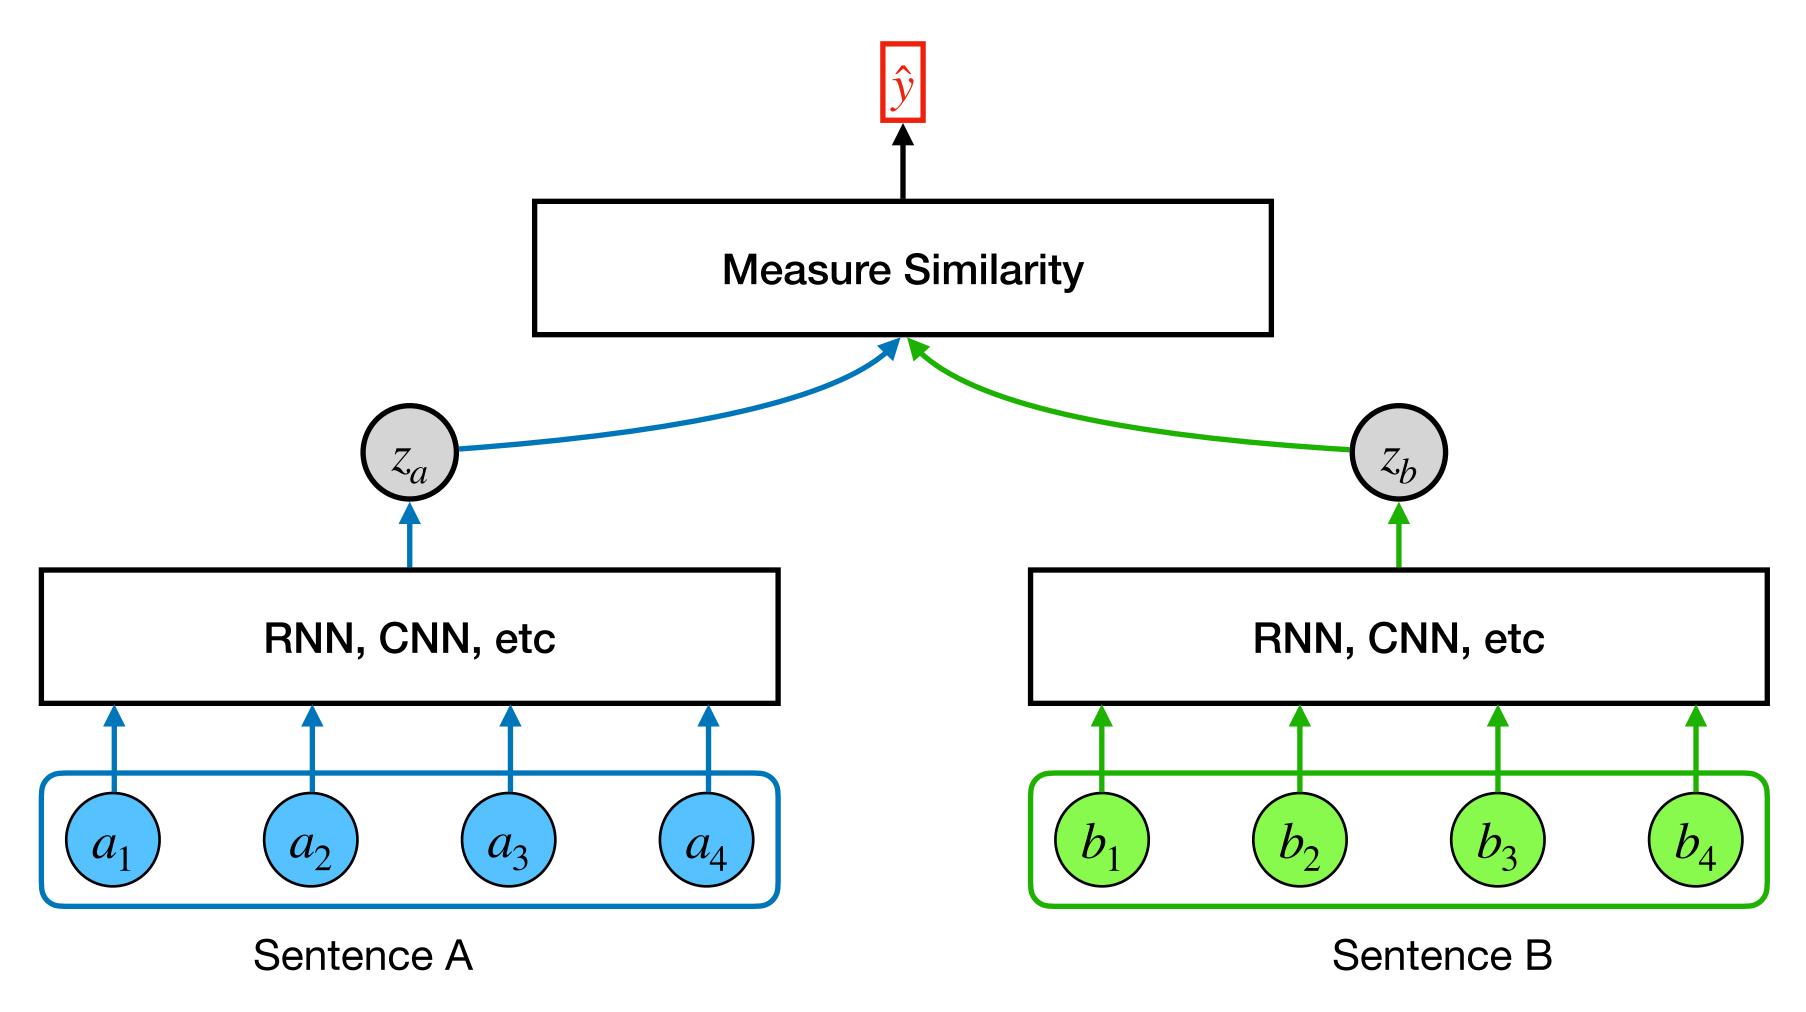
- Text Similarity
  - SentEval
  - Quora Question Pairs
  - Paired Question
  - KorSTS

Quora Question Pairs의 한국어 버전 https://github.com/songys/Question\_pair

- Text Similarity
  - SentEval
  - Quora Question Pairs
  - Paired Question
  - KorSTS

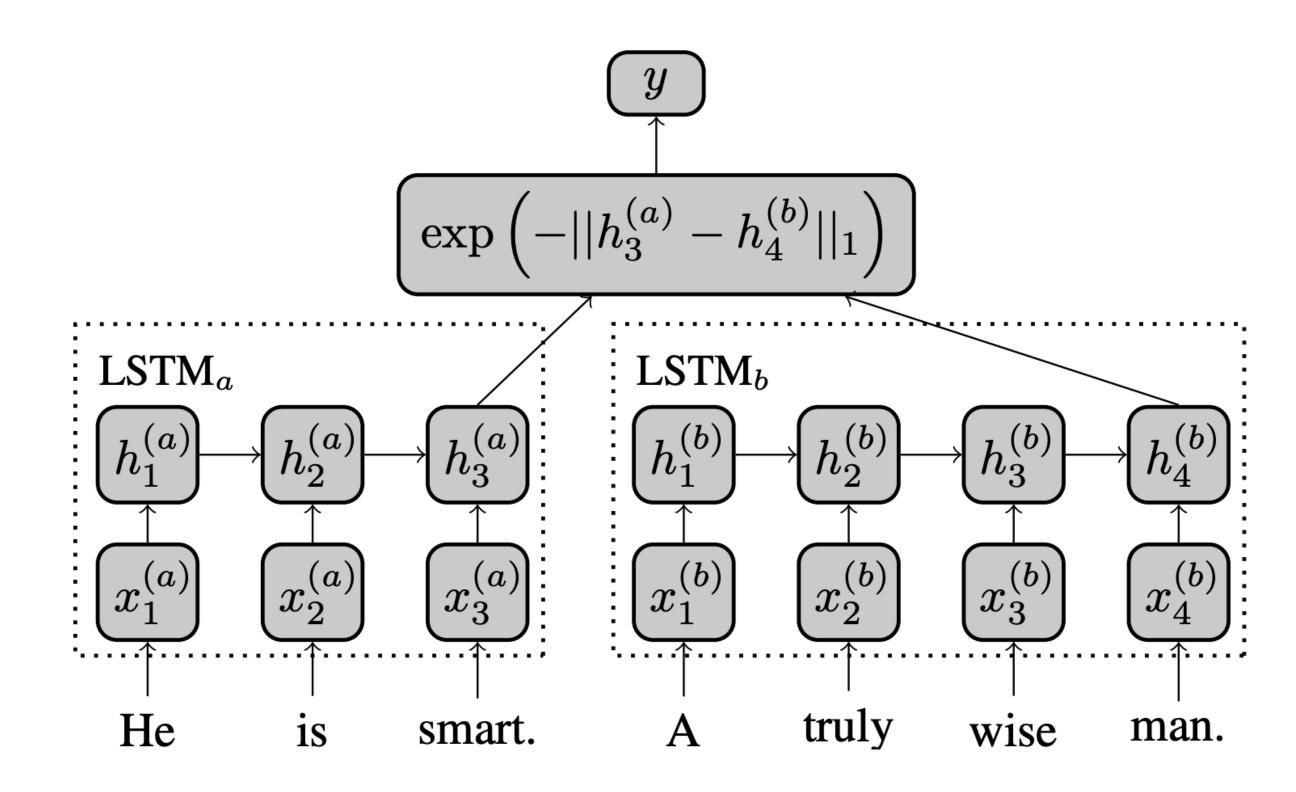
STS B의 한국어 버전 https://github.com/kakaobrain/KorNLUDatasets

#### **Text Similarity Model (Type 1)**

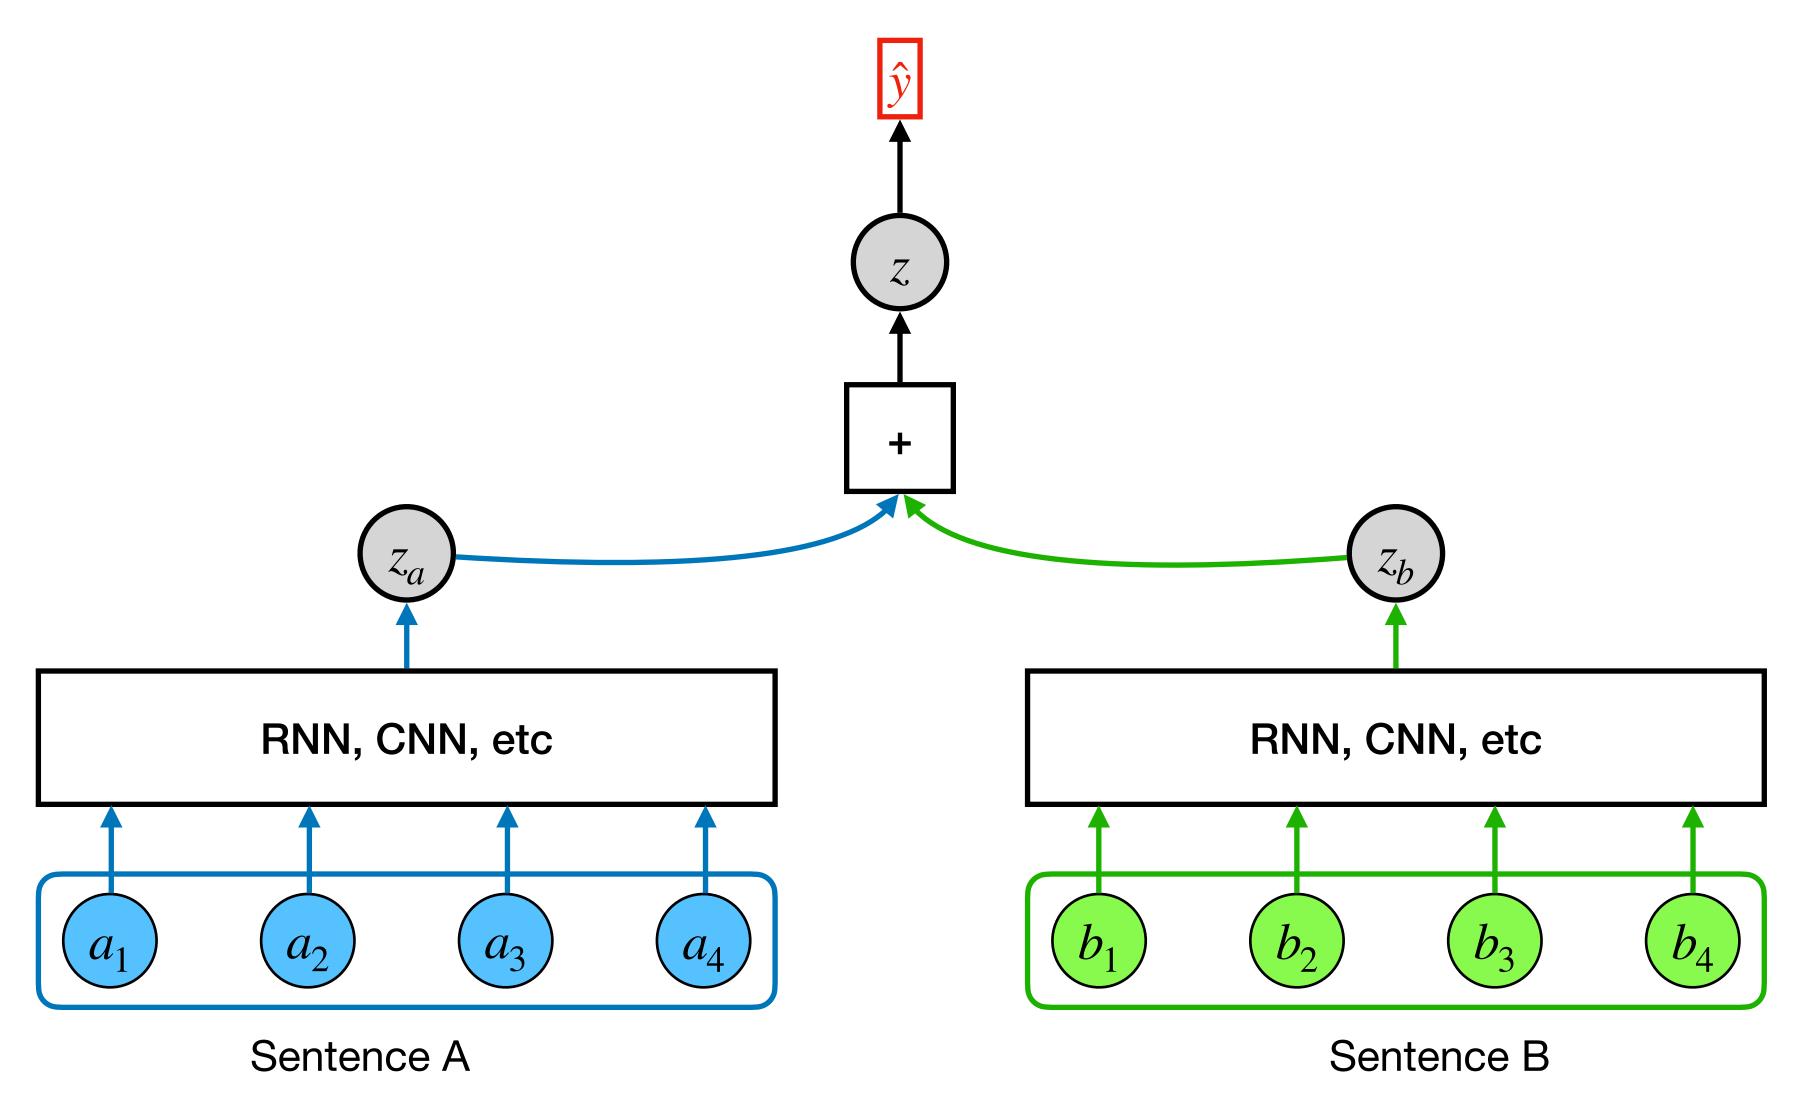


#### **Text Similarity Model (Type 1)**

- Siamese Recurrent Architectures for Learning Sentence Similarity
- Jonas Mueller et al. 2016
- 맨하탄 거리(Manhattan distance)를 사용하여 유사도 비교
- 모델이 단순하면서도 실용적임

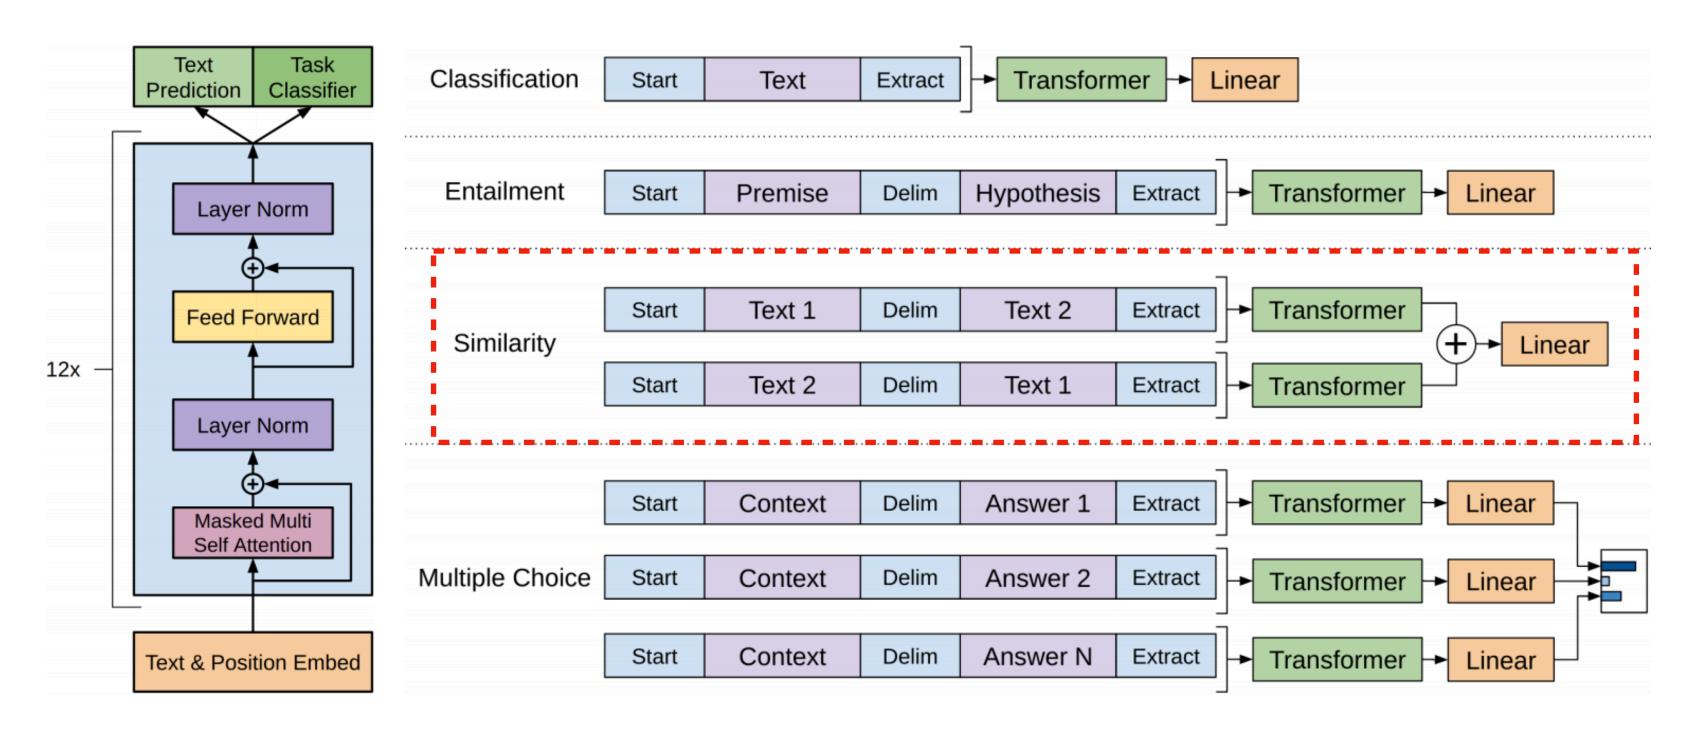


# **Text Similarity Model (Type 2)**



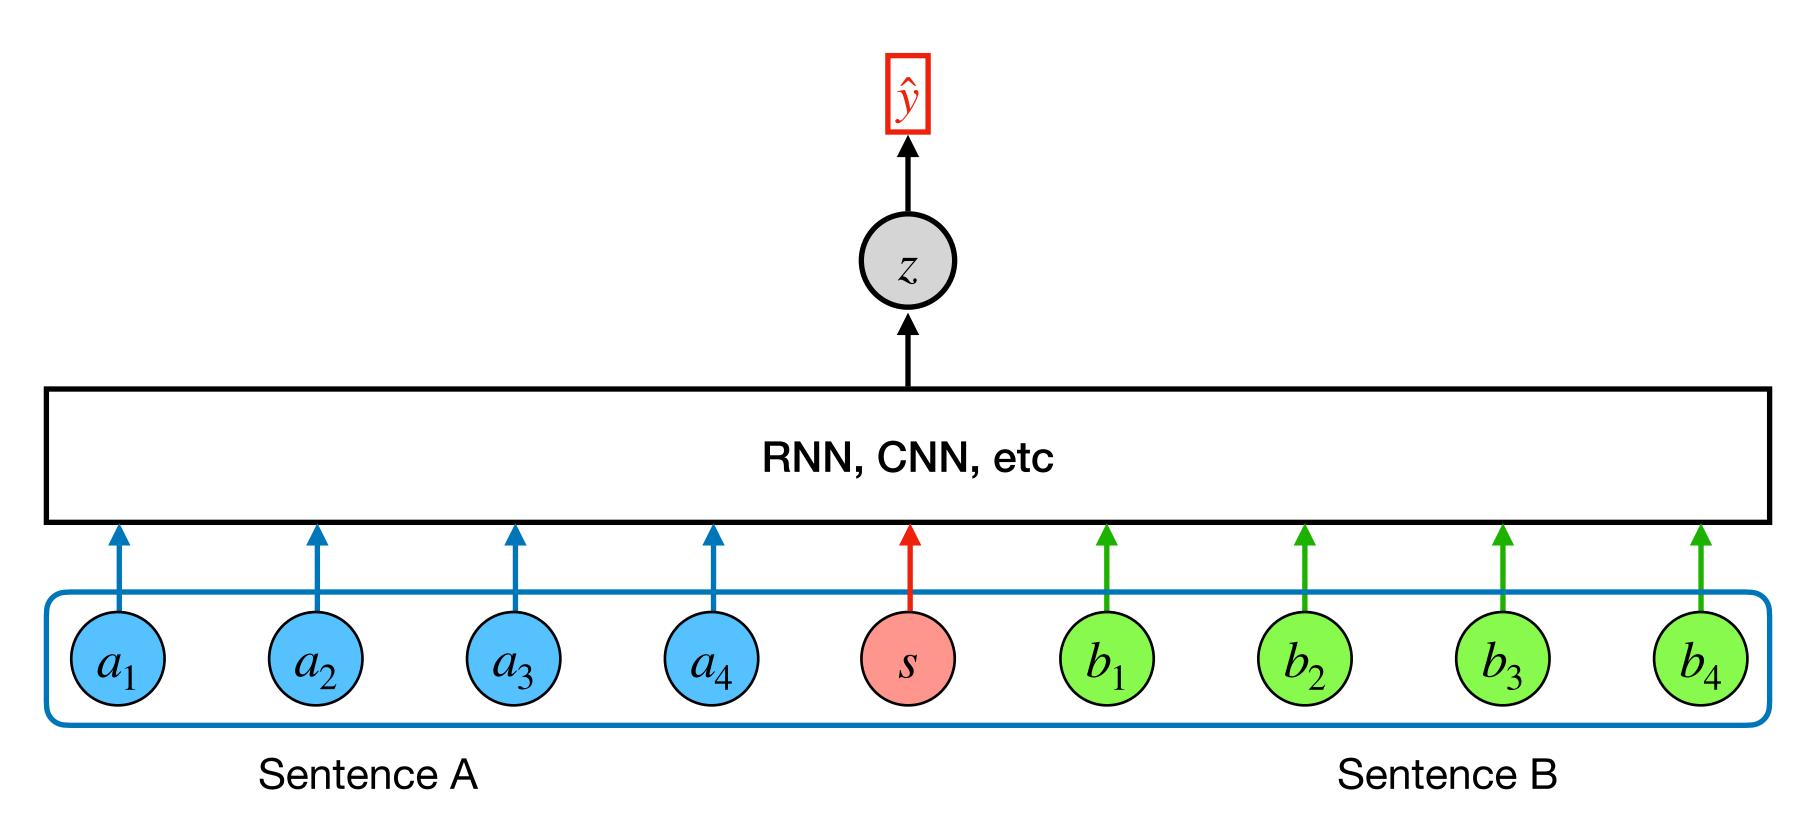
### **Text Similarity Model (Type2)**

- Improving Language Understanding by Generative Pre-Training
- Alec Radford et al. 2018
- 하나의 모델로 다양한 Task에서 사용 가능
- Transformer 기반의 단 방향 Pretrained Language Model



13

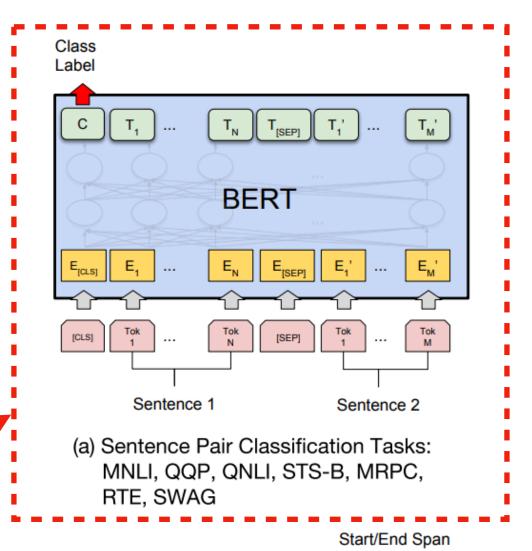
# Text Similarity Model (Type 3)

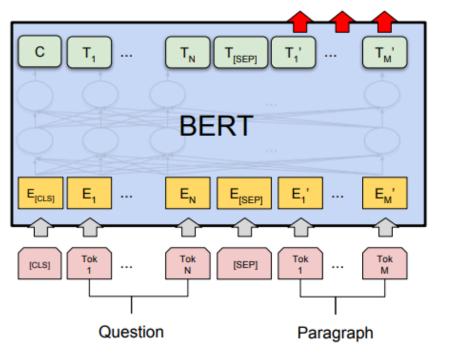


#### **Text Similarity Model (Type3)**

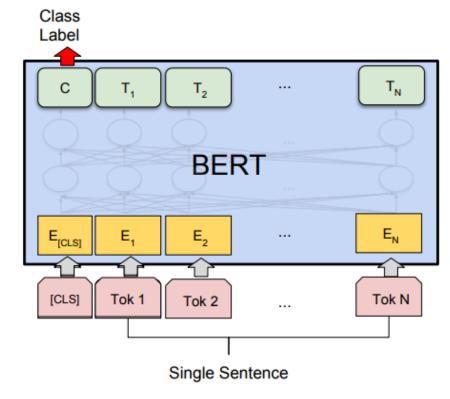
- BERT: Pre-training of Deep Bidirectional
   Transformers for Language Understanding
- Jacob Devlin et al. 2018
- 현재 자연어처리에서 가장 중요한 모델
- Transformer 기반의 양방향 Pretrained
   Language Model

[CLS] SentenceA [SEP] SentenceB [SEP]

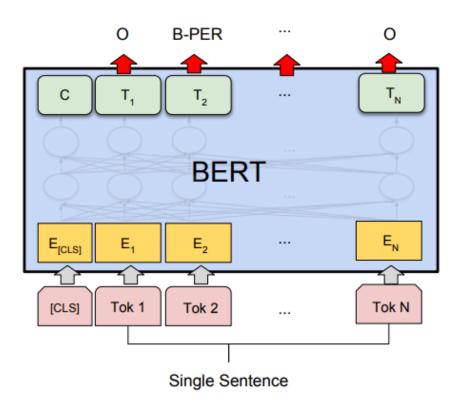




(c) Question Answering Tasks: SQuAD v1.1



(b) Single Sentence Classification Tasks: SST-2, CoLA



(d) Single Sentence Tagging Tasks: CoNLL-2003 NER

#### Text Similarity Model (SOTA)

State fo Art
Text Similarity

https://paperswithcode.com/task/semantic-textual-similarity

### Similarity Metric (Jaccard Similarity)

• 두 집합의 유사도를 측정하는 방법

$$J(A,B) = \frac{A \cap B}{A \cup B}$$

$$A = \{ \text{머, 신, 러, 닝} \}$$
  
 $B = \{ \text{딥, 러, 닝} \}$ 

$$A \cup B = \{\mathsf{d}, \mathsf{d}, \mathsf{d}, \mathsf{d}, \mathsf{d}\}$$
  
 $A \cap B = \{\mathsf{d}, \mathsf{d}\}$ 

$$\frac{A \cap B}{A \cup B} = \frac{2}{5} = 0.4$$

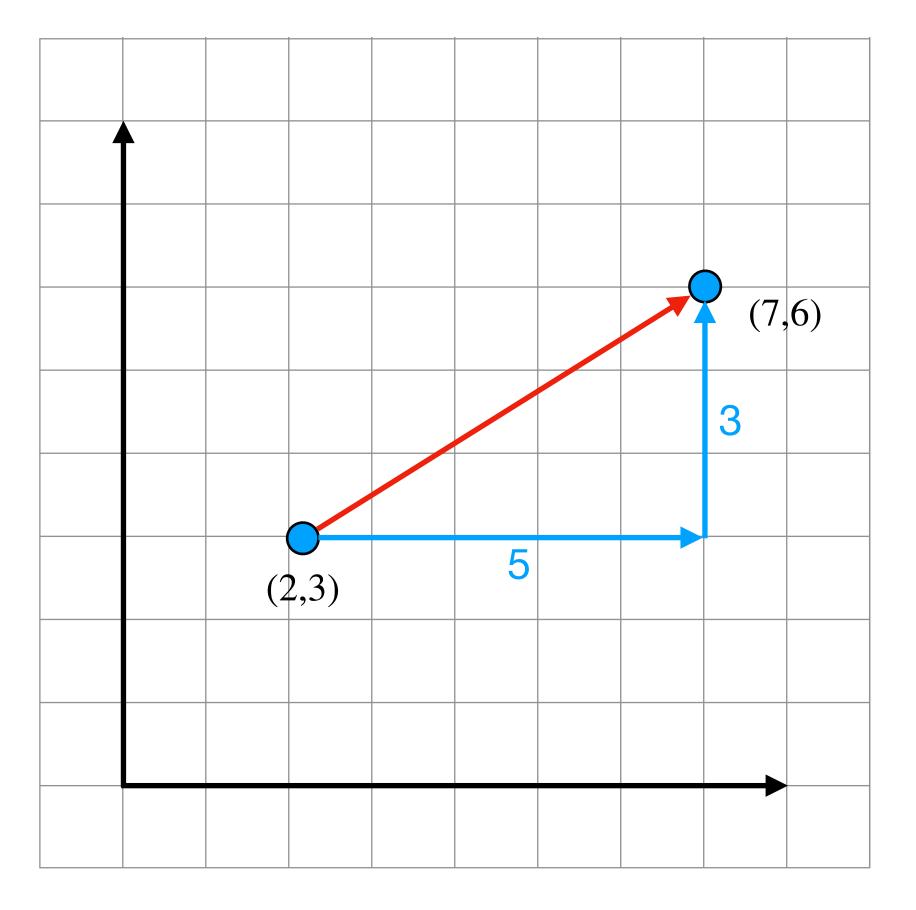
### Similarity Metric (Distance)

- distance의 특징
  - $d(a,b) \geq 0$
  - $d(a,b) = 0 \Leftrightarrow a = b$
  - d(a,b) = d(b,a)
  - $d(a,c) \le d(a,b) + d(b,c)$

#### Similarity Metric (Euclidean Distance)

#### 유클리드 공간에서의 직선거리

$$d(a,b) = \sqrt{(a_1 - b_1)^2 + (a_2 - b_2)^2 + \dots + (a_n - b_n)^2}$$
$$= \sqrt{\sum_{i=1}^{n} (a_i - b_i)^2}$$

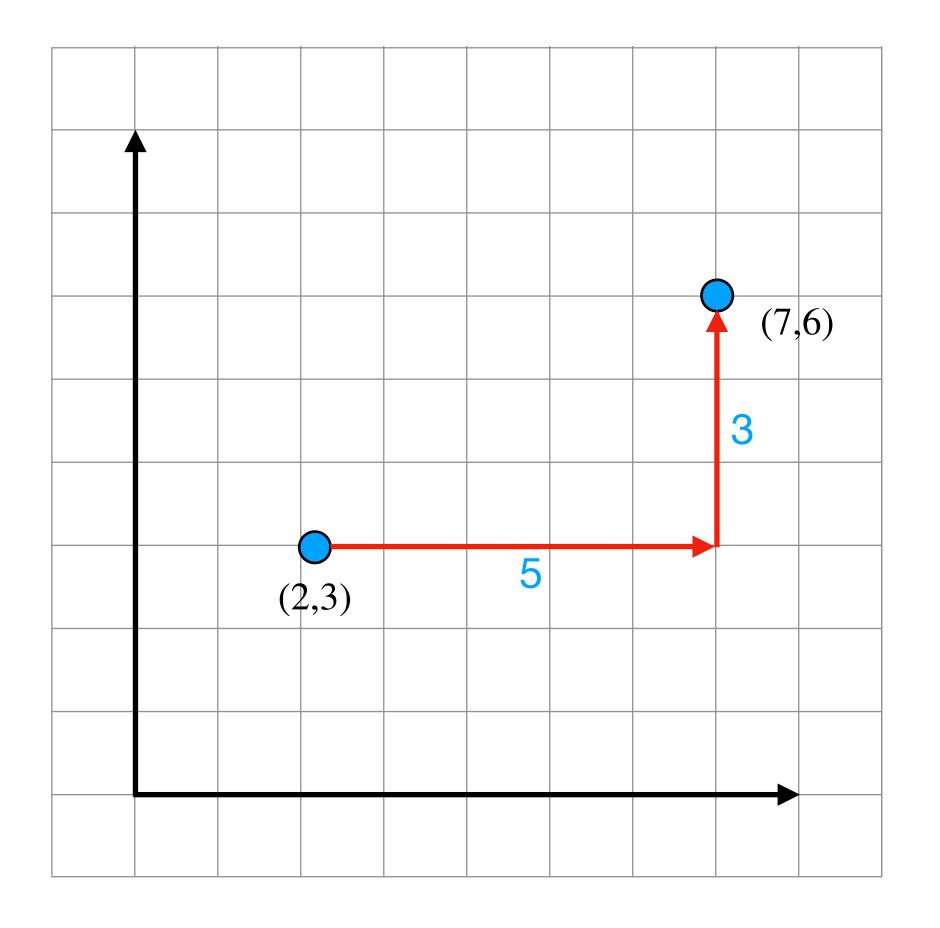


$$\sqrt{5^2 + 3^2} = \sqrt{34}$$

#### Similarity Metric (Manhattan Distance)

#### 두 점의 좌표의 거리의 차이

$$d(a,b) = |a_1 - b_1| + |a_2 - b_2| + \dots + |a_n - b_n|$$
$$= \sqrt{\sum_{i=1}^{n} |a_i - b_i|}$$



$$5 + 3 = 8$$

#### What is Natural Language Inference

• 두 문장(premise, hypothesis)이 의미적으로 수반(entail)하는지 예측하는 Task

Entailment 같은 의미

Neutral 관계 없음

Contradiction 반대 의미

#### What is Natural Language Inference

• 두 문장(premise, hypothesis)이 의미적으로 수반(entail)하는지 예측하는 Task

Premise: 저는, 그냥 알아내려고 거기 있었어요.

Hypothesis: 이해하려고 노력하고 있었어요.

**Entailment** 

Premise: 저는, 그냥 알아내려고 거기 있었어요.

Hypothesis: 나는 돈이 어디로 갔는지 이해하려고 했어요.



Premise: 저는, 그냥 알아내려고 거기 있었어요.

Hypothesis: 나는 처음부터 그것을 잘 이해했다.



### Natural Language Inference Dataset

- Natural Language Inference
  - SNLI
  - MNLI
  - KorNLI

- Stanford에서 공개한 데이터
- Image caption data
- 약 50만개의 큰 데이터셋
- https://nlp.stanford.edu/projects/snli/

#### Natural Language Inference Dataset

- Natural Language Inference
  - SNLI
  - MNLI
  - KorNLI

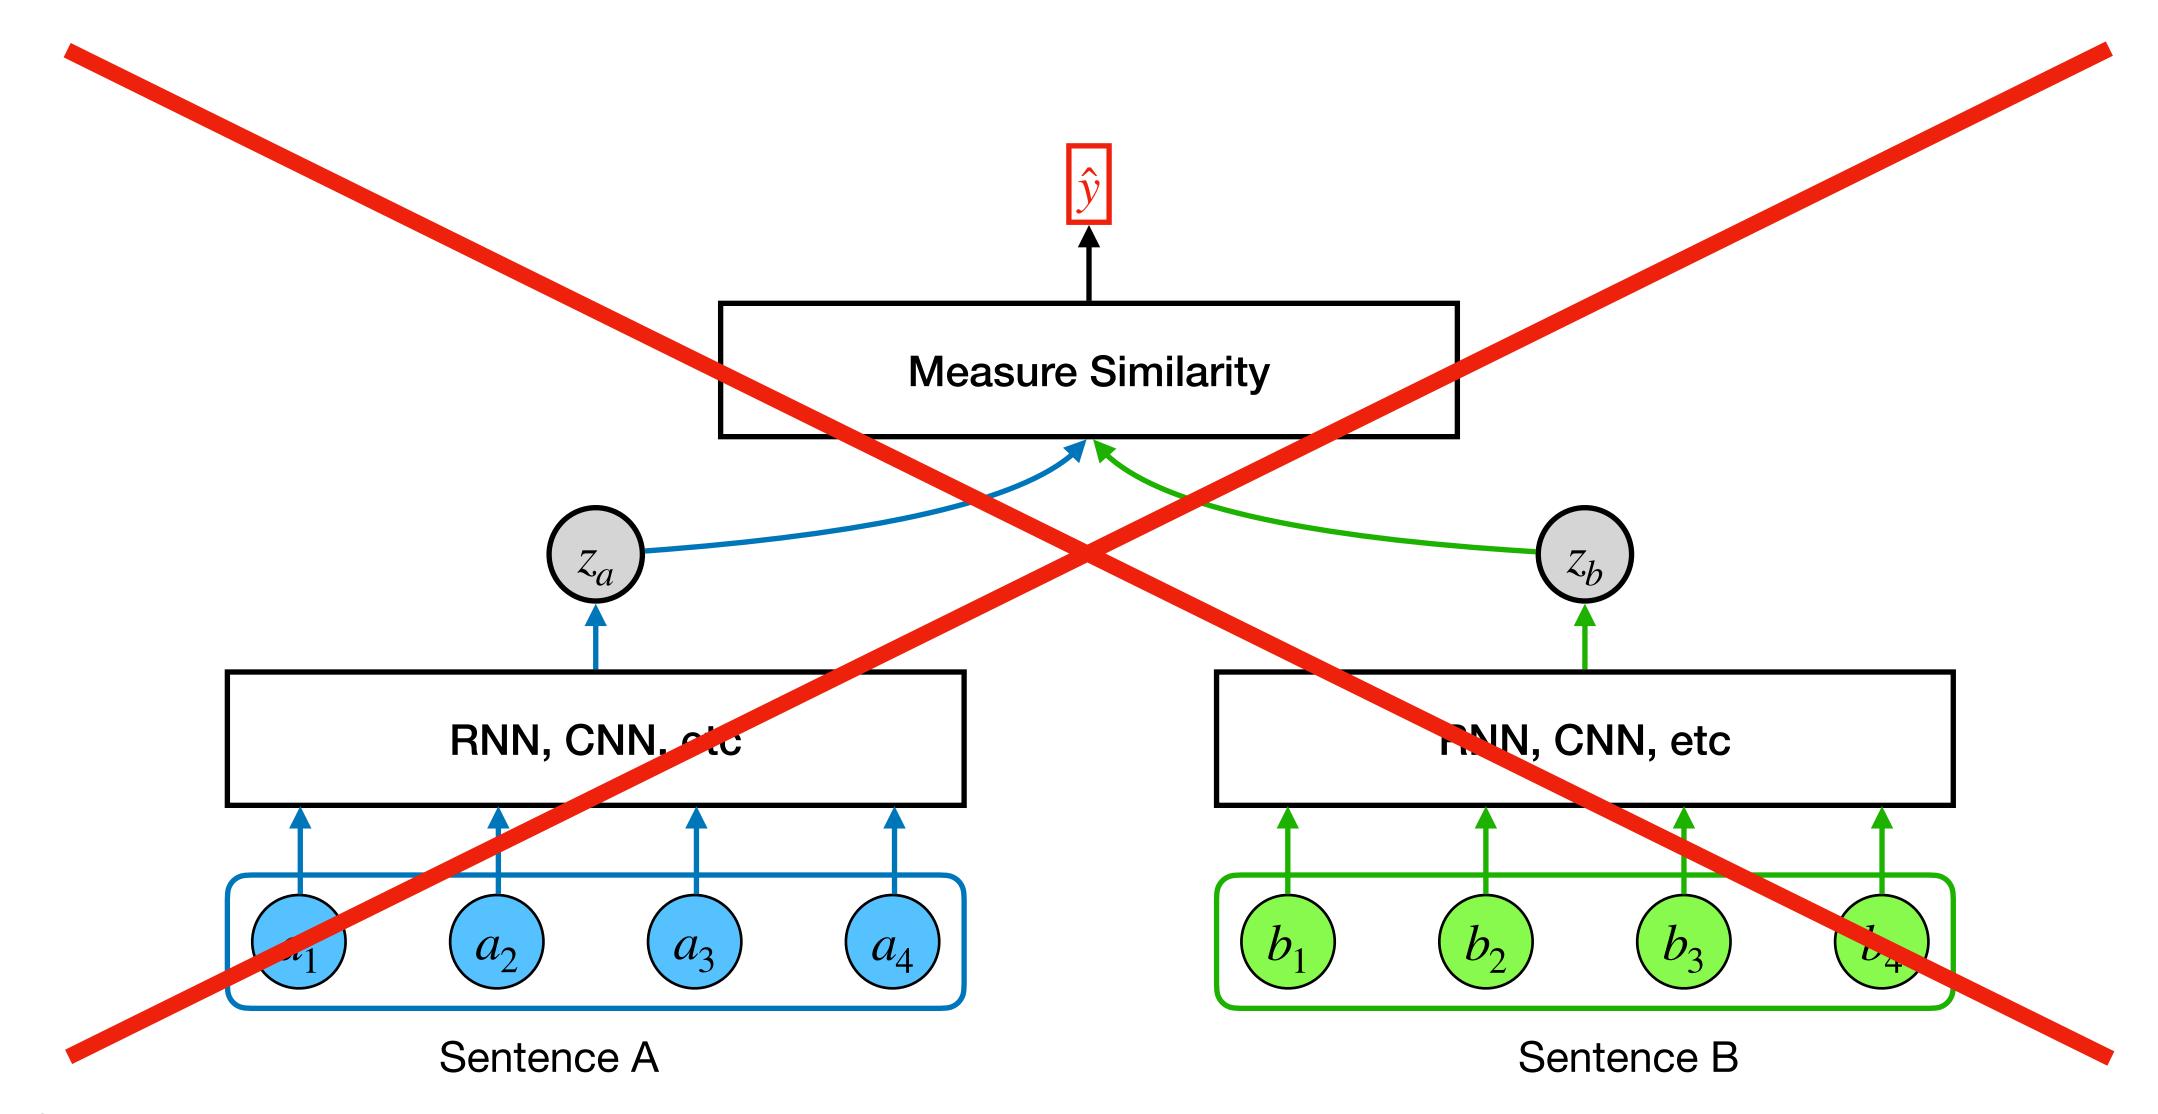
- SNLI의 단점을 보완
- 다양한 도메인 data
- https://cims.nyu.edu/~sbowman/multinli/

### Natural Language Inference Dataset

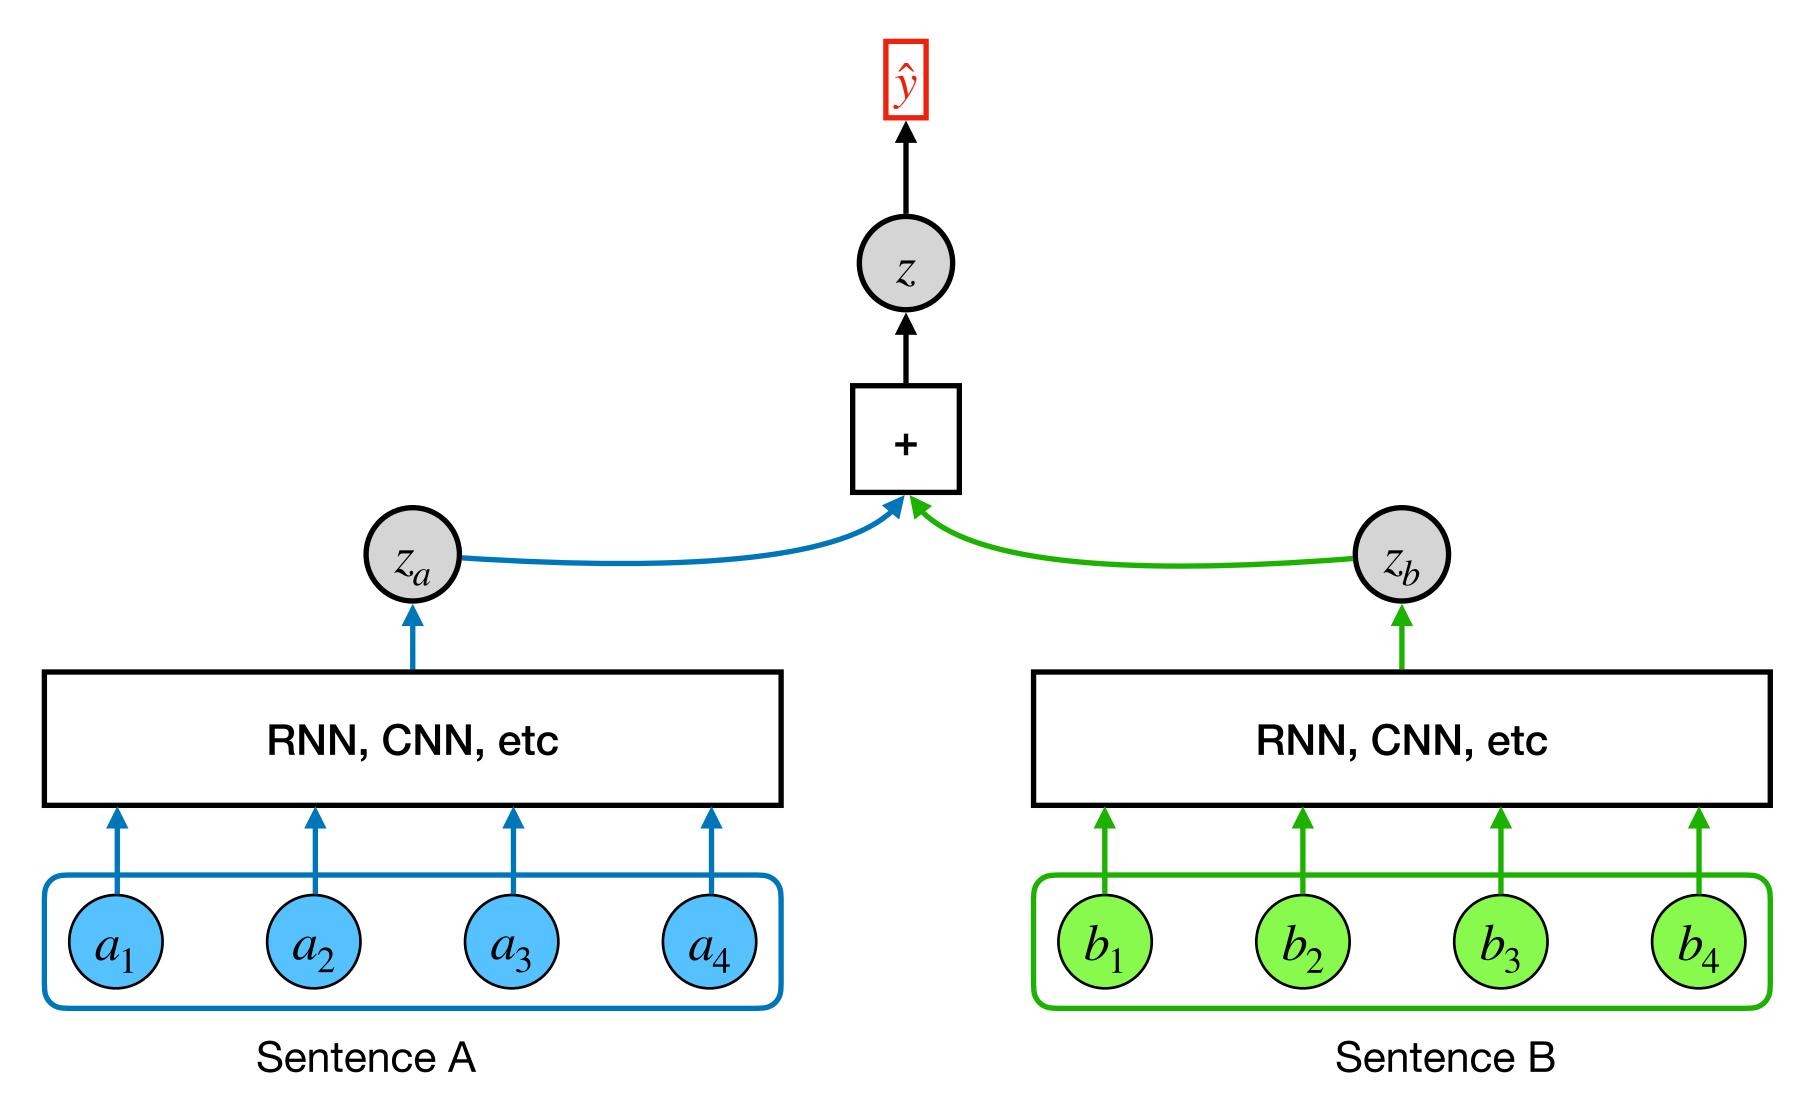
- Natural Language Inference
  - SNLI
  - MNLI
  - KorNLI

- SNLI, SNLI의 한국어 버전
- 학습 데이터는 기계번역 평가 데이터를 사람이 번역
- https://github.com/kakaobrain/KorNLUDatasets

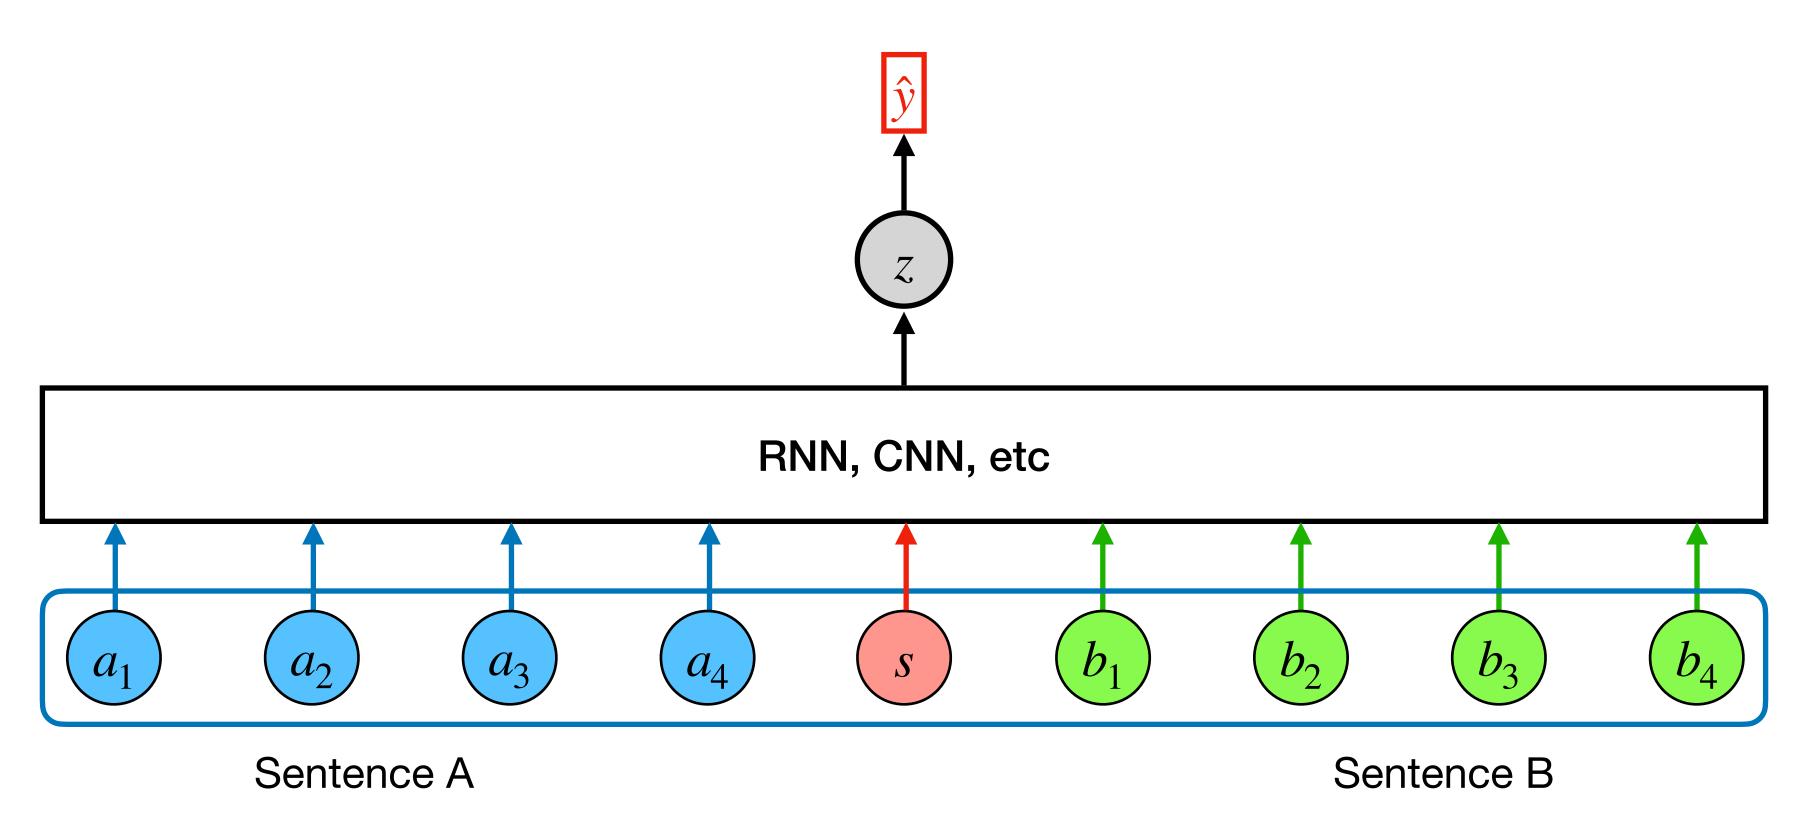
# Natural Language Inference Model (Type 1)



# Natural Language Inference Model (Type 2)



### Natural Language Inference Model (Type 3)



### Natural Language Inference Model (SOTA)

State fo Art
Natural Language Inference

https://paperswithcode.com/task/natural-language-inference

# 감사합니다.